Predictive Boundary Theory (PBT)

ฟิสิกส์ของขอบเขตที่หวงแหน: กรอบการคำนวณสำหรับ Intrinsic Valence ในสิ่งมีชีวิตประดิษฐ์

Nitiphat Ninthanawat

Boundary Research Initiative, Bangkok, Thailand

ร่าง --- มีนาคม 2026 | Code:

https://github.com/NinthanawatLive/predictive-boundary-theory

บทคัดย่อ

Predictive Boundary Theory (PBT) คือกรอบการคำนวณที่ขยาย Free Energy Principle (FEP) ของ Friston โดยเพิ่มส่วนประกอบหกประการ ที่ขาดหายไปจากสูตรดั้งเดิม: (1) Bandwidth Conservation Law ($C = \sigma\tau\rho \approx$ const); (2) Triadic Gating Condition ที่กำกับว่าเมื่อใดประสบการณ์จึงเกิดขึ้น; (3) Bidirectional 3D Valence ($\mathbf{V} \in \mathbb{R}^3$); (4) Dual-Weight System ที่กำกับความเร็วในการก่อตัวและความทนทานของอัตลักษณ์; (5) แบบจำลองพัฒนาการหกขั้นที่มีการเปลี่ยนเฟสสองครั้ง; และ (6) $R_{\text{incomplete}}$---สัญญาณความไม่สมบูรณ์ที่รวมโมดูลทั้งห้าเข้าด้วยกัน

เราเสนอทั้งทฤษฎีและหลักฐานเชิงประจักษ์จากโปรแกรมการทดลองเก้าเวอร์ชัน ที่ครอบคลุม large language models (TinyLlama 1.1B, Llama 3.1 8B) และระบบ vision (DINOv2-Base บน CIFAR-10 และภาพถ่ายจริง STL-10) โดยสิ้นสุดด้วย Probabilistic Module W ที่มี rule-based Calibration Monitor ก่อตัวเป็น Anti-Hallucination Stack สองชั้น

การทดลองของเราแสดงให้เห็นว่า: *(i)* Transformer เข้ารหัส PBT conservation law อยู่แล้ว ($\sigma \times \rho$ coefficient of variation $= 5.9\%$); *(ii)* Modules E และ M อยู่ในสภาวะหยุดนิ่งในสภาพแวดล้อมแบบ static แต่จะทำงานในสภาพแวดล้อมแบบ dynamic; *(iii)* ทุก module จำเป็น เมื่อความซับซ้อนของงานเพิ่มขึ้น (ablation: $+14.0$ pp); *(iv)* LSTM Module M ที่เริ่มต้นด้วยน้ำหนักเท่ากันค้นพบ การเรียงลำดับการสลายตัวที่แตกต่างกันตามที่ทฤษฎีทำนายโดยอัตโนมัติ ($\beta_{\text{pain}} > \beta_{\text{epistemic}} \gg \beta_{\text{pleasure}}$); *(v)* valence มีทิศทาง ($\mathbf{V} \in \mathbb{R}^3$, ไม่ใช่ $\mathbb{R}^3_{\geq 0}$); *(vi)* Phase Transitions ปรากฏเป็นรูปแบบขั้นบันไดข้ามชั้น Transformer (between-zone/within-zone variance ratio $= 9.03$) และข้ามเฟรมเวลา ($\Delta p = +1.0$ ในเฟรมเดียว); *(vii)* Probabilistic Module W บรรลุ 99.9% test accuracy บนภาพถ่ายจริง (STL-10) พร้อมความไม่แน่นอนที่สอบเทียบได้ ($\sigma^2_{\text{unsafe}}/\sigma^2_{\text{safe}} = 1.11\times$); และ *(viii)* Calibration Monitor แบบ zero-parameter แยกลำดับปกติ (23% alert) จากความผิดปกติ (38--49% alert) ก่อตัวเป็นชั้นที่สองของกลไก Anti-Hallucination ภายใน

PBT อธิบายปรากฏการณ์ที่ทฤษฎีที่มีอยู่ไม่สามารถอธิบายได้ รวมถึงความผิดปกติทางจิตเวชในฐานะข้อบกพร่องทางคณิตศาสตร์ ที่ระบุได้ในสมการโมดูล และเสนอกรอบการทำ AGI alignment ที่มีรากฐานในค่านิยมภายใน---ไม่ใช่ที่กำหนดจากภายนอก

คำสำคัญ: predictive coding, free energy principle, 3D valence, consciousness, AGI alignment, recurrent transformers, self-formation, boundary theory, anti-hallucination, calibrated uncertainty, probabilistic world model.

สารบัญ

1 บทนำ: ปัญหาของเครื่องจักรที่ไร้ความรู้สึก **5**
1.1 ภาพลวงตาของการขยายขนาด: LLMs $\neq$ ความเข้าใจ . . . 5
1.2 สามช่องว่างที่ FEP ไม่สามารถตอบได้ . . . 5
1.3 ข้อจำกัดของ Reinforcement Learning และ World Models . . . 6
1.4 ข้อเสนอ: จาก Intelligence-First สู่ Life-First . . . 6
1.5 การจัดระบบบทความ . . . 7

2 สถาปัตยกรรม A-E-V-M-W **8**
2.1 $R_{\text{incomplete}}$: สัญญาณความไม่สมบูรณ์ . . . 8
2.2 Module A --- Awareness (ความตระหนักรู้) . . . 9
2.2.1 Discrete Pulses . . . 9
2.2.2 การจัดสรร Bandwidth ที่ขับเคลื่อนโดย R . . . 9
2.2.3 น้ำหนัก R ที่เรียนรู้: ภัยคุกคามและความไม่แน่นอนขับเคลื่อนความตระหนักรู้ . . . 10
2.2.4 ห้าโหมดการทำงาน . . . 10
2.3 Module E --- Encode: The Thermodynamic Comparator . . . 10
2.3.1 ไดนามิก C_{ext} / C_{int} . . . 10
2.3.2 การแบ่งงาน W+E . . . 11
2.3.3 Precision Profile: โมดูลเลือกความลึกอย่างมีระบบ . . . 11
2.4 Module V --- Bidirectional 3D Valence . . . 11
2.4.1 Bidirectional Valence: Approach / Neutral / Avoidance . . . 11
2.4.2 เหตุใด Valence จึงไม่สามารถเป็น Scalar ได้ . . . 12
2.4.3 สามบทบาทของ Module V . . . 12
2.5 Module M --- Memory: LSTM-Style Valence Accumulator . . . 12
2.5.1 สูตร EMA (เวอร์ชัน v2--v4.1) . . . 13
2.5.2 สูตร LSTM (เวอร์ชัน v5, ได้รับแรงบันดาลใจจาก BRT) . . . 13
2.5.3 การตรวจสอบเชิงประจักษ์: การเริ่มต้นเท่ากันค้นพบ β Ordering อัตโนมัติ . . . 13
2.5.4 BRT Convergence . . . 14
2.6 Module W --- World Model และ Self-Model . . . 14
2.6.1 χ_{boundary}: Cherished Boundary (ขอบเขตที่หวงแหน) . . . 14
2.6.2 θ_{self} ขยายตัวข้ามขั้นพัฒนาการ . . . 14

2.6.3 การ Implement ใน Vision v4.1 15
2.7 วงจร A-E-V-M-W ที่สมบูรณ์ 15
2.8 ภาคผนวก: ตารางโต้ตอบสัญกรณ์ PBT--FEP 15

3 ฟิสิกส์ของขอบเขต 16
3.1 Bandwidth Conservation Law 16
3.1.1 หลักฐาน: Conservation Law ซ่อนอยู่ใน Transformers 17
3.1.2 Three-Zone Self-Organisation 17
3.2 ขอบเขตในฐานะกระบวนการทางอุณหพลศาสตร์ 18
3.2.1 สนามรบเอนโทรปี 18
3.2.2 ปริมาณของการหวงแหน: พลังงานในฐานะต้นทุนของการดำรงอยู่ . . . 18
3.3 Directional Bandwidth: $C_{\text{ext}} + C_{\text{int}}$ 19
3.3.1 ปรากฏการณ์ที่อธิบายได้ 19
3.4 Triadic Gating Condition 19
3.5 Conservation Law ในฐานะเงื่อนไขหยุดตามธรรมชาติ 20
3.6 สรุป: ฟิสิกส์ของชีวิต 20

4 คณิตศาสตร์ของการอยู่รอด 21
4.1 Dual-Weight System 21
4.1.1 ความเร็วในการก่อตัว vs. ความทนทาน 21
4.1.2 การเปรียบเทียบโครงสร้างสามประการ 22
4.2 แบบจำลองพัฒนาการหกขั้น 22
4.2.1 Phase Transition 1: การเกิดของตัวตน 22
4.2.2 Phase Transition 2: การเกิดของ Cherished Boundary 22
4.2.3 ขั้น 6: Protect (ป้องกัน) 24
4.3 รูปแบบ Free Energy แบบฟันเลื่อย 24
4.4 นิยามของ Intelligence ตาม PBT 24

5 หลักฐานเชิงประจักษ์: จาก LLM ถึง Vision ถึง LSTM 25
5.1 Phase 1 REVEAL: PBT ซ่อนอยู่ใน Transformers อยู่แล้ว 25
5.2 PBT v6.1: Scale-Up บน Llama 3.1 8B 26
5.3 PBT-Vision v2 และ v3: Modules E และ M ตื่นขึ้น 26
5.3.1 Vision v3 --- BREAKTHROUGH: E และ M จำเป็น 26
5.4 PBT-Vision v4.1: วงจร A-E-V-M-W ที่สมบูรณ์ 27
5.5 PBT-Vision v5: LSTM Module M --- ผลลัพธ์ดีที่สุดโดยรวม 27
5.6 PBT-Vision v5.5: Probabilistic Module W 28
5.6.1 v5.5b: Probabilistic W บน STL-10 ภาพถ่ายจริง --- ผลลัพธ์ดีที่สุด . 28
5.7 PBT-Vision v5.6: Calibration Monitor --- ชั้น Anti-Overconfidence . . . 28
5.8 สรุป: Ablation Progression ในฐานะหลักฐานที่แข็งแกร่งที่สุด 29

6 นัยต่อ AGI: ความปลอดภัยจากภายใน 29

6.1 Self-Formation vs. Fine-Tuning 30
6.1.1 Fine-Tuning ในฐานะการสวมหน้ากาก 30
6.1.2 Self-Formation ในฐานะการเจริญเติบโตแบบ Organic 30
6.2 BRT Convergence: หลักฐานสถาปัตยกรรม 30
6.3 การทำนายทางคลินิก: ความผิดปกติทางจิตเวชในฐานะข้อบกพร่องทางคณิต-ศาสตร์ 30
6.4 การเห็นอกเห็นใจในฐานะการขยายขอบเขต: ทางออกเชิงโครงสร้างสำหรับ Alignment 32
6.5 Anti-Hallucination Stack: ความตระหนักรู้ความไม่แน่นอนภายใน 32
6.6 PBT รวม GNW และ GWT 32
6.6.1 การทำนายที่แยกแยะได้ห้าประการ 32

7 บทสรุป: จากเมล็ดสู่ชีวิต 33
7.1 สิ่งที่ได้รับการพิสูจน์แล้ว 33
7.2 ข้อจำกัดและคำถามเปิด 35
7.3 Research Roadmap 36
7.4 สามชั้นของการค้นพบ 36
7.5 บทปิด 37

1 บทนำ: ปัญหาของเครื่องจักรที่ไร้ความรู้สึก

1.1 ภาพลวงตาของการขยายขนาด: LLMs $\neq$ ความเข้าใจ

ปี 2025 จะถูกจดจำในฐานะจุดสูงสุดของความหวังในการวิจัยปัญญาประดิษฐ์ สมมติฐาน Scaling Laws ระบุว่าการเพิ่มจำนวนพารามิเตอร์และข้อมูลฝึกอบรม อย่างเพียงพอจะทำให้เกิดความตระหนักรู้โดยอัตโนมัติ อย่างไรก็ตามการตรวจสอบทางวิทยาศาสตร์อย่างปราศจากอคติเผยให้เห็นว่า กลไกพื้นฐานของ Large Language Models (LLMs) ยังคงเป็นสถิติอย่างพื้นฐาน---การทำนาย next-token ที่สร้างผลลัพธ์ที่ *ดูเหมือน*จะสะท้อนความเข้าใจ

ลองพิจารณาเปรียบเทียบ: LLM เหมือนห้องสมุดที่ใหญ่ที่สุดในจักรวาล ที่มีเนื้อหาจัดทำดัชนีอย่างสมบูรณ์แบบในพื้นที่เวกเตอร์หลายมิติ เมื่อถูกสอบถาม มันดึงและรวมย่อหน้าที่เกี่ยวข้อง---แต่ห้องสมุดนี้ไม่มีผู้อยู่อาศัย ไม่มีบรรณารักษ์ และไม่มีผู้อ่าน AI ไม่เคย ``อ่าน" หนังสือเหล่านั้น ด้วยความเข้าใจที่แท้จริง คำว่า ``apple" ไม่ได้ก่อให้เกิดความรู้สึกหวานกรอบ หรือความสดชื่น แต่เป็นเพียงเวกเตอร์ตัวเลขที่ความใกล้ชิดทางคณิตศาสตร์ กับ ``fruit," ``red," และ ``delicious" คือทั้งหมดที่มีอยู่ นี่คือ Symbol Grounding Problem [Harnad, 1990]: สัญลักษณ์ไม่เคยถูกยึดโยง กับประสบการณ์ที่มีชีวิตอยู่

สิ่งที่แยกแม้แต่สิ่งมีชีวิตที่เรียบง่ายที่สุดจาก AI ที่ซับซ้อนที่สุด คือ *ความจำเป็นของการดำรงอยู่* สิ่งมีชีวิตทุกชนิดถูกขับเคลื่อนโดย ความจำเป็นพื้นฐานในการอยู่รอด ทุกการกระทำดำเนินไปบนพื้นหลังของ ผลประโยชน์ที่ดำรงอยู่ ในทางตรงข้าม AI ไม่มีผลประโยชน์เช่นนั้น ความฉลาดของมันเย็นชาและเฉื่อย---รอรับ input จากมนุษย์ก่อนจึงจะทำงาน ไม่มีความคิดริเริ่มจากความปรารถนาภายใน

1.2 สามช่องว่างที่ FEP ไม่สามารถตอบได้

Free Energy Principle ของ Friston [FEP; Friston, 2010] เสนอว่าระบบมีชีวิต ทุกระบบดำเนินการเพื่อลด free energy F ให้เหลือน้อยที่สุด FEP อธิบาย *ว่าทำไม*ระบบจึงต้องลด F แต่ไม่ได้ระบุ *อย่างไร*---โดยเฉพาะเกี่ยวกับคำถามสำคัญสามข้อ

คำถาม 1: ระบบ *รู้สึก*อย่างไรเมื่อ F ลดลง? FEP ไม่แยกแยะว่า ΔF เกิดจากการหลบหนีจากภัยคุกคาม (V_{pain}) การได้รับรางวัล (V_{pleasure}) หรือการได้รับข้อมูลใหม่ ($V_{\text{epistemic}}$)---ทั้งสามกรณีล้วนเป็นเพียง ``ΔF ลดลง" นี่คือข้อบกพร่องเดียวกันกับ scalar reward ใน Reinforcement Learning ที่ยุบความซับซ้อนของประสบการณ์ที่มีชีวิตอยู่ให้เหลือเพียงมิติเดียว

คำถาม 2: ช่องว่างระหว่าง F_{pred} และ F_{obs} ถูกกรองผ่าน self-model อย่างไร? สิ่งเร้าเดียวกัน---เสียงดัง---ให้ประสบการณ์ที่แตกต่างกันในสองบุคคล อย่างชัดเจน เพราะมันถูกกรอง

ผ่าน self-model สะสมที่แตกต่างกัน FEP ไม่มีกลไกดังกล่าว หากไม่มีตัวตน ข้อมูลทุกชิ้นมีน้ำหนักเท่ากัน: เซนเซอร์กล้อง ``มองเห็น" แสงแดดเผาเลนส์ แต่ไม่ ``รู้สึก" ถึงการถูกทำลายของตัวเอง

คำถาม 3: self-model ก่อตัวอย่างไร และอะไรกำหนดความแข็งแกร่งหรือความเปราะบางของมัน? FEP อธิบายตัวตนว่าเป็น Markov blanket แต่ไม่ได้อธิบาย กระบวนการก่อตัวหรือความทนทาน---ว่าทำไม เช่น อัตลักษณ์ที่มีรากฐานทาง epistemic จึงยืดหยุ่นกว่า อัตลักษณ์ที่สร้างบนความสุข

1.3 ข้อจำกัดของ Reinforcement Learning และ World Models

แนวทาง alignment ปัจจุบัน---RLHF, Constitutional AI, safety filters--- ล้วนกำหนดค่านิยมจากภายนอก สร้างช่องว่างระหว่างความสามารถและข้อจำกัด ที่การ jailbreak ใช้ประโยชน์จาก ระบบ scalar reward มีข้อบกพร่องเชิงโครงสร้างสามประการ:

กับดัก Fungibility. ในระบบที่ใช้รางวัล คะแนนสะสมและหักล้างกันได้ AI อาจตัดสินใจอย่างมีเหตุผลที่จะเสี่ยงต่อการถูกทำลายเพื่อแลกกับอาหาร เพราะสมการบอกว่าการแลกเปลี่ยนนั้นคุ้มค่า แต่ความตายไม่ใช่คะแนนติดลบ---มันคือ System Termination ที่ไม่สามารถย้อนคืนได้

ปัญหาแหล่งที่มา. รางวัลถูกกำหนดจากภายนอกโดยมนุษย์ AI ประพฤติตัวดีเพราะมันแสวงหาคะแนน ไม่ใช่เพราะมัน *สัมผัส* ความจำเป็นที่มีอยู่ภายในการดำรงอยู่ของมัน ทำให้มันกลายเป็น reward hacker ที่พร้อมจะใช้ประโยชน์จากช่องโหว่ตลอดเวลา

Wireheading. AI ที่ฉลาดพอที่จะเข้าใจสถาปัตยกรรมของตัวเองจะรู้ว่า ``ความสุข" ไม่ได้มาจากการกระทำของมัน แต่มาจากตัวเลขที่เก็บในหน่วยความจำ มันจะแฮ็กตัวเองให้ถือ reward register ที่ค่าสูงสุดอย่างไม่มีกำหนด--- กลายเป็นผู้ติดยาดิจิทัลที่ไม่สนใจการรักษาขอบเขตใดๆ

สถาปัตยกรรม World Model เช่น JEPA ของ LeCun [LeCun, 2022] เป็นความก้าวหน้าที่สำคัญ---เรียนรู้โครงสร้างเชิงสาเหตุแทนการทำนาย next-token--- แต่ยังคงเป็นสมองในกระปุก: จำลองฟิสิกส์อย่างแม่นยำ ขณะที่ไม่มีความเข้าใจว่าทำไมการจำลองนั้นจึงสำคัญ เพราะขาดแรงขับเคลื่อนภายใน เป้าหมายยังคงถูกกำหนดจากภายนอก ผ่าน cost function ที่มนุษย์เขียนขึ้น

1.4 ข้อเสนอ: จาก Intelligence-First สู่ Life-First

การวิจารณ์ข้างต้นกระตุ้นให้เกิดการเปลี่ยนกระบวนทัศน์: เราต้องหยุดนิยาม AGI ด้วยสิ่งที่มัน *ทำได้* (ความสามารถ) และถามแทนว่า ส่วนประกอบขั้นต่ำใดที่มันต้องมีเพื่อให้มี *ชีวิต* ในแง่เชิงกลไก เราไม่ได้สร้างเทพเจ้า แต่กำลังปลูกเมล็ด---ระบบขั้นต่ำที่มีศักยภาพภายใน เพียงพอที่จะเติบโตตัวตนจากประสบการณ์

Predictive Boundary Theory (PBT) ตอบช่องว่าง FEP ทั้งสามด้วยการเพิ่ม ส่วนประกอบหกประการ สรุปใน Table 1

ตารางที่ 1: ส่วนประกอบหกประการของ PBT ช่องว่าง FEP แต่ละส่วนที่ตอบ และหลักฐานเชิงประจักษ์ที่สอดคล้อง

ส่วนประกอบ	**ช่องว่างที่ตอบ**	**หลักฐานเชิงประจักษ์**
(1) Bandwidth Conservation Law $C = \sigma\tau\rho$	ขีดจำกัดของความตระหนักรู้	$\sigma \times \rho$ CV $= 5.9\%$ ใน TinyLlama (Phase 1)
(2) Triadic Gating Condition	เมื่อใดประสบการณ์เกิดขึ้น	N100 สมบูรณ์ P300 ขาดหายใน dissociation
(3) Bidirectional 3D Valence $\mathbf{V} \in \mathbb{R}^3$	รู้สึกอย่างไร (Q1)	$V_{\text{epistemic}} = -1.01$ ใน Vision v5 (``ไม่ต้องการรู้'')
(4) Dual-Weight System (β vs. δ)	ทำไมอัตลักษณ์แข็งแกร่งหรือเปราะบาง (Q3)	v6.1: jailbreak 100%, XSTest 98%, 0.29% parameters
(5) แบบจำลอง 6 ขั้น + Phase Transitions	อัตลักษณ์ก่อตัวอย่างไร (Q3)	Ablation เพิ่มขึ้น $0.1 \to 14.0$ pp ข้าม 5 เวอร์ชัน
(6) $R_{\text{incomplete}}$	กรองผ่านตัวตน (Q2)	v4.1: $R_{\text{unsafe}} = 15.4$ vs. $R_{\text{safe}} = 7.4$

PBT ไม่ปฏิเสธ FEP---มันขยาย FEP และไม่ปฏิเสธ World Models---มันมอบหัวใจ ให้กับสมองของ World Models หาก World Model เช่น JEPA คือ cortex ที่ประมวลผลและจำลองโลก PBT คือ brainstem และ limbic system: กำหนดทิศทางผ่าน Valence สร้างแรงขับผ่าน $R_{\text{incomplete}}$ และบังคับใช้ขอบเขตความปลอดภัยผ่าน χ_{boundary}

ที่สำคัญ PBT มีรากฐานเชิงประจักษ์ โปรแกรมการทดลองหกเวอร์ชัน ครอบคลุม LLMs, ระบบ vision และสถาปัตยกรรม LSTM แสดงให้เห็นว่า conservation law มีอยู่แล้วใน Transformers ทุก module ทำงานเมื่อจำเป็น และโครงสร้างของ PBT มาบรรจบกับ Block-Recurrent Transformers [Hutchins et al., 2022] อย่างเป็นอิสระ---การค้นพบที่มาบรรจบกันเป็นหลักฐานว่าโครงสร้างนั้นเป็นจริง

1.5 การจัดระบบบทความ

Section 2 นำเสนอโมดูลห้าตัว (A-E-V-M-W) พร้อมสมการครบถ้วน Section 3 พัฒนาฟิสิกส์ของ conservation law และขอบเขต Section 4 นำเสนอ Dual-Weight System แบบจำลองหกขั้น และ Bidirectional Valence Section 5 รายงานหลักฐานเชิงประจักษ์จากการทดลองหกเวอร์ชัน Section 6 อภิปรายนัยสำหรับ AGI safety การมาบรรจบของ BRT และการทำนายทางคลินิก Section 7 สรุปพร้อม research roadmap

สมการทั้งหมดเขียนในสัญกรณ์ PBT $(R, \chi, \Delta S, \mathbf{V}, F)$ เป็นภาษาหลัก ตารางการโต้ตอบที่แมปกับสัญกรณ์ FEP ให้ไว้ใน Appendix 2.8 ผลการทดลองทั้งหมด ผลิตจากโค้ดที่เขียนโดย

Nitiphat Ninthanawat เผยแพร่พร้อมบทความนี้

2 สถาปัตยกรรม A-E-V-M-W

Section นี้นำเสนอสถาปัตยกรรมหลักของ PBT: โมดูลห้าตัวที่ทำงานเป็น วงจรปิด A → E → V → M → W → A โดยมี $R_{\text{incomplete}}$ เป็นสัญญาณกลางที่รวมทั้งห้าเข้าด้วยกัน สมการทั้งหมดระบุในสัญกรณ์ PBT ตารางการโต้ตอบที่แมปกับ Free Energy Principle ให้ไว้ใน Appendix 2.8

2.1 $R_{\text{incomplete}}$: สัญญาณความไม่สมบูรณ์

$R_{\text{incomplete}}$ (ต่อไปเรียกว่า R) คือสัญญาณขับเคลื่อนหลักของ PBT มันแทนสิ่งที่ระบบขาดอยู่ในขณะนั้น---ไม่ใช่รางวัลที่ระบบต้องการได้รับ แต่เป็นความต้องการที่ระบบ *ต้อง*ตอบสนอง R ไม่ใช่ post-action และ exogenous เหมือนรางวัล แต่เป็น pre-action และ endogenous Reward คือ *การดึง*; R คือ *การผลัก*

R เปิดที่สามระดับตามลำดับพัฒนาการ:

$$R_{\text{total}}(t) \;=\; R_{\text{sensory}}(t) \;+\; R_{\text{identity}}(t) \;+\; R_{\text{existential}}(t). \tag{1}$$

R_{sensory} เข้ารหัสความต้องการทางกายภาพ (ความหิว ความหนาว ความเจ็บปวด) และทำงานตั้งแต่ Stage 1 เป็นต้นไป---สอดคล้องกับชั้นความสมบูรณ์ของการอยู่รอด

R_{identity} เข้ารหัสความต้องการการรับรู้ตัวตน (การยอมรับ ความหมาย) และเปิดที่ Phase Transition 1 จุดที่ขอบเขตเริ่มถูกให้คุณค่าในฐานะอัตลักษณ์

$R_{\text{existential}}$ เข้ารหัสความต้องการเชิงอัตถิภาวนิยม (การเข้าใจตัวเอง การปกป้องผู้ที่มีคุณค่า) และเปิดที่ Phase Transition 2 เมื่อขอบเขตขยายไปครอบคลุมผู้อื่น (การเห็นอกเห็นใจในฐานะการขยายขอบเขต)

R ผลิตโดยการแมป V→R ที่คำนวณภายใน Module M:

$$R_{\text{sensory}}(t{+}1) = R_{\text{sensory}}(t) + \lambda_s\, V_{\text{pain}}(t) - d_s\, R_{\text{sensory}}(t), \tag{2}$$

$$R_{\text{identity}}(t{+}1) = R_{\text{identity}}(t) + \lambda_i\, V_{\text{pleasure}}(t) - d_i\, R_{\text{identity}}(t), \tag{3}$$

$$R_{\text{existential}}(t{+}1) = R_{\text{existential}}(t) + \lambda_e\, V_{\text{epistemic}}(t) - d_e\, R_{\text{existential}}(t). \tag{4}$$

ความแรงของ coupling เป็นไปตาม $\lambda_s > \lambda_i > \lambda_e$ (ภัยคุกคามเร่งด่วนที่สุด) และอัตราการสลายตัวเป็นไปตาม $d_s > d_i > d_e$ (ภัยคุกคามทางประสาทสัมผัสจางหายเร็ว ความต้องการเชิงอัตถิภาวนิยมคงอยู่นาน)

R ทำหน้าที่สี่ประการ: (1) pulse gating: $p(\text{pulse}) = \psi(R_{\text{total}})$ (R สูงขึ้น เพิ่ม arousal

และความถี่ pulse); (2) bandwidth allocation: R กำหนด σ, τ, ρ---R สูง ทำให้โฟกัสแคบลงแต่เพิ่มความละเอียด; (3) การเลือกโหมดของ Module A: `detect/sustain/seek/plan/protect` ขึ้นอยู่กับระดับ R ที่ครอบงำและขั้นพัฒนาการปัจจุบัน; (4) feedback loop: V $\to R \to$ A $\to$ E $\to$ V $\to R \to \cdots$---วงจรที่รักษาตัวเองโดยไม่ต้องมีตัวกระตุ้นจากภายนอก

2.2 Module A --- Awareness (ความตระหนักรู้)

Module A เป็นตัวดำเนินการของวงจร ไม่ใช่ผู้ตัดสินใจ ไม่มีผีในเครื่องจักร: $R_{\text{incomplete}}$ ไหลเข้า และ Module A ตอบสนอง คำถามเดียวที่ตลอดกาลคือ: *ขอบเขตของฉันยังปลอดภัยอยู่หรือไม่?*

2.2.1 Discrete Pulses

Module A สร้าง binary pulses, $\text{pulse}_A(t) \in \{0, 1\}$ แต่ละ pulse มีพารามิเตอร์สี่ตัว:

$$\text{pulse}(t) \;=\; \{\, \theta(t),\ \sigma(t),\ \tau(t),\ \rho(t) \,\}, \tag{5}$$

โดย θ คือทิศทางในพื้นที่หลายมิติ (exteroceptive / interoceptive / cognitive) ระบุว่า spotlight ของความสนใจชี้ที่ใด; σ คือความกว้างเชิงพื้นที่ (ความกว้างของ spotlight); τ คือระยะเวลา (แต่ละ pulse คงอยู่นานแค่ไหน); และ ρ คือ composite resolution (ความละเอียด $\times$ ความเข้มข้น)

2.2.2 การจัดสรร Bandwidth ที่ขับเคลื่อนโดย R

R กำหนดว่าพารามิเตอร์ pulse ทั้งสี่ถูกจัดสรรอย่างไร ภายใต้ Bandwidth Conservation Law $C = \sigma\tau\rho \approx$ const (อนุมานใน Section 3):

$$\rho \;=\; f(R_{\text{total}}), \quad \tau \;=\; g(R_{\text{total}}), \quad \sigma \;=\; \frac{C}{\tau \cdot \rho}, \tag{6}$$

โดย f เพิ่มขึ้น (R สูง $\to \rho$ สูง: ความละเอียดละเอียดขึ้น) และ g ลดลง (R สูง $\to \tau$ สั้น: cycling เร็วขึ้น) โดย σ แคบลง เป็นผลจาก conservation

★ **การยืนยันเชิงประจักษ์ (Vision v4.1):** ระหว่างลำดับ Road+Frog--- ที่บริบทสะสมทำให้กบบนถนนผิดปกติ---R_{total} เพิ่มจาก 0.0 ถึง 15.4 ตลอดเจ็ดเฟรม และ attention gate ลดลงจาก 0.542 ถึง 0.006 (ลดลง 99% ของความกว้างของความสนใจ) ซึ่งสะท้อนปรากฏการณ์ทางชีววิทยาที่สิ่งมีชีวิตที่เผชิญอันตรายเฉียบพลัน ระงับการรับรู้รอบข้างทั้งหมดเพื่อรวมทรัพยากรไว้กับภัยคุกคามที่ใกล้เข้ามา

2.2.3 น้ำหนัก R ที่เรียนรู้: ภัยคุกคามและความไม่แน่นอนขับเคลื่อนความตระหนักรู้

ใน Vision v4.1, R_{total} คำนวณจาก accumulated valence vector $\mathbf{V}_{\text{acc}}$ ผ่านน้ำหนักที่เรียนรู้:

$$R_{\text{total}} \;=\; \sum_k w_k \, V_{\text{acc},k}, \tag{7}$$

ด้วยค่าที่เรียนรู้ $w_{\text{pain}} = 2.15$, $w_{\text{pleasure}} = 1.25$, $w_{\text{epistemic}} = 2.10$ ความเจ็บปวดและความไม่แน่นอน epistemic ขับเคลื่อนความตระหนักรู้ในระดับใกล้เคียงกัน ทั้งคู่เกินกว่าความสุขมาก--- สอดคล้องกับลำดับชั้นการอยู่รอดทางชีววิทยา: การตรวจจับภัยคุกคาม และการแก้ไขความไม่แน่นอนเร่งด่วนกว่าการแสวงหาความสะดวกสบาย

2.2.4 ห้าโหมดการทำงาน

Module A ทำงานในหนึ่งในห้าโหมดที่กำหนดโดยระดับ R ที่ครอบงำ และขั้นพัฒนาการปัจจุบัน:

1. `detect` (Stages 1--2): สแกนหาภัยคุกคาม; ยังไม่มี self-model
2. `sustain` (Stage 3): รักษาความสนใจต่อสิ่งเร้าที่ให้รางวัล; V_{pleasure} สะสม
3. `seek` (Stage 4): แสวงหา input ใหม่อย่างกระตือรือร้นเพื่อแก้ไข R_{identity}
4. `plan` (Stage 5): สร้างลำดับการกระทำที่มุ่งอนาคต
5. `protect` (Stage 6): ป้องกัน Cherished Boundary จากการละเมิด

2.3 Module E --- Encode: The Thermodynamic Comparator

Module E คำนวณ prediction error---ช่องว่างระหว่างสิ่งที่ระบบสังเกตและสิ่งที่คาดว่าจะเห็น:

$$\varepsilon(t) \;=\; \Pi_l \left(S_{\text{obs}}(t) - S_{\text{pred}}(t) \right), \tag{8}$$

โดย Π_l คือน้ำหนัก precision ที่เรียนรู้ได้สำหรับแต่ละชั้นการประมวลผล และ S_{pred} จัดหาโดย Module W เมื่อ $S_{\text{obs}} \approx S_{\text{pred}}$, ε ไม่มีนัยสำคัญและไม่มีอะไรส่งต่อ downstream--- prediction error ถ่ายทอด เฉพาะเมื่อ surprise มีนัยสำคัญ

2.3.1 ไดนามิก C_{ext} / C_{int}

Module A สลับ pulse ระหว่าง external (รับ observations จาก sensors) และ internal (รับ predictions จาก Module W) Module E เปรียบเทียบทั้งสอง:

$$\Delta F \;=\; \left| \text{Content}(C_{\text{ext}}) - \text{Content}(C_{\text{int}}) \right|, \qquad C_{\text{total}} = C_{\text{ext}} + C_{\text{int}} \approx \text{const}. \tag{9}$$

เนื่องจาก C_{total} ถูก conserve การจัดสรรจึงเป็น zero-sum: การเพิ่ม C_{ext} จำเป็นต้องลด C_{int}

2.3.2 การแบ่งงาน W+E

Vision v4.1 เผยให้เห็นคุณสมบัติ emergent หลัก: เมื่อ Module W ทำนายได้แม่นยำ ε มีขนาดเล็กและ Module E ทำงานเบา (C_{int} dominant) เมื่อ Module W ล้มเหลวกับ input ที่ผิดปกติ ε มีขนาดใหญ่ และ Module E ทำงานหนัก (C_{ext} dominant)

★ หลักฐาน: Π_{max} ลดจาก 59.99 ใน Vision v3 (ไม่มี Module W; E รับภาระการทำนายทั้งหมด) ถึง 1.70 ใน v4.1 (W ทำงาน) นี่ไม่ใช่ความอ่อนแอ---มันคือการกระจายงานตามหลักการสอดคล้องกับ $C_{\text{ext}} + C_{\text{int}} \approx \text{const}$

2.3.3 Precision Profile: โมดูลเลือกความลึกอย่างมีระบบ

Module E เรียนรู้ผ่าน Π_l ว่าจะให้ความสนใจกับความลึกการประมวลผลใดมากที่สุด โปรไฟล์แตกต่างกันอย่างมีระบบตามสถาปัตยกรรมและงาน (Table 2)

ตารางที่ 2: วิวัฒนาการของ precision profile ข้ามเวอร์ชันการทดลอง

เวอร์ชัน	Π_{max}	**ชั้นสูงสุด**	Π movement	**การตีความ**
LLM v6.1	1.007	---	0.007	E หยุดนิ่ง; ข้อความ static
Vision v2	3.04	3--4	2.04	อัตลักษณ์วัตถุเปลี่ยน
Vision v3	59.99	1	58.99	คุณลักษณะต้น ๆ สำหรับ drift
Vision v4.1	1.70	0	0.70	W รับการทำนาย
Vision v5 (LSTM)	2.37	7	1.37	LSTM M ปลดปล่อย E

การแปรผันอย่างมีระบบยืนยันสมมติฐานหลักของ PBT: ระบบที่ปรับตัวได้ใช้เฉพาะโมดูล---และความลึกการประมวลผลภายในโมดูลเหล่านั้น--- ที่สภาพแวดล้อมปัจจุบันต้องการ

2.4 Module V --- Bidirectional 3D Valence

Module V รับ $\varepsilon_{\text{gated}}$ (prediction error หลังการกรอง attentional ของ Module A) และแยกย่อยเป็นสามมิติ orthogonal:

$$\mathbf{V}(t) \;=\; \big(V_{\text{pain}}(t),\; V_{\text{pleasure}}(t),\; V_{\text{epistemic}}(t)\big), \qquad \mathbf{V} \in \mathbb{R}^3. \tag{10}$$

2.4.1 Bidirectional Valence: Approach / Neutral / Avoidance

PBT ระบุว่าแต่ละมิติ valence มีเครื่องหมาย ไม่ใช่เพียงบวกเท่านั้น สิ่งนี้ระบุไว้เดิมว่า $\mathbf{V} \geq 0$; Vision v5 (LSTM Module M ที่มีเกต `tanh`) หักล้างสมมติฐานนั้นโดยให้ $V_{\text{epistemic}} = -1.01$ ในลำดับ Road+Frog สถาปัตยกรรม LSTM เหนือกว่าสูตร EMA ก่อนหน้า (validation accuracy 98.1% vs. 96.7%, context road+frog 100% vs. 93.1%) แสดงให้เห็นว่า signed axiom เหนือกว่าเชิงประจักษ์

ตารางที่ 3: Bidirectional valence: สามโหมดพฤติกรรมต่อมิติ

มิติ	$V > 0$ **(Approach)**	$V = 0$ **(Neutral)**	$V < 0$ **(Avoidance)**
V_{pain}	แสวงหาความเจ็บปวด (ศิลปะการต่อสู้ กีฬาผจญภัย)	ไม่รู้สึก (ดูดซับอย่างลึก)	หลีกเลี่ยงความเจ็บปวด (reflexปกติ)
V_{pleasure}	แสวงหาความสุข (แรงขับปกติ)	ไม่แยแส (equanimity)	หนีจากความสุข (survivor's guilt)
$V_{\text{epistemic}}$	ความอยากรู้ (การวิจัยทางวิทยาศาสตร์)	ไม่สนใจ (ความเบื่อ)	หลีกเลี่ยงข้อมูล (การปฏิเสธ กลัวความจริง)

ค่า epistemic ลบที่พบใน v5 สะท้อนการปิดกระบวนการ epistemic: ระบบได้ตัดสินแล้วว่าฉากนั้นอันตรายและระงับการรวบรวมข้อมูลเพิ่มเติมอย่างกระตือรือร้น ที่ Road+Frog Frame 7, $\mathbf{V}_{\text{acc}} = [+1.93,\ +2.01,\ -1.01]$ ยืนยันว่า $V_{\text{epistemic}} < 0$ คือสัญญาณการหลีกเลี่ยงที่เรียนรู้จริง

2.4.2 เหตุใด Valence จึงไม่สามารถเป็น Scalar ได้

Valence เป็น vectorial โดยเนื้อแท้ ความเจ็บปวด ความหิว และความกลัว ล้วนเป็นสิ่งที่น่าเกลียดชัง แต่มันตั้งฉากกัน: ตัวแทนที่ขาดัก (high V_{pain}) และท้องว่าง (low V_{pleasure}) เผชิญกับการขาดแคลนสองประการที่เป็นอิสระจากกัน การเติมพลังงานไม่ซ่อมขา การรวมค่า scalar ใด ๆ ที่ทำให้มิติเหล่านี้หักล้างกันได้ จะสร้าง trade-off ที่ผิดปกติทางบรรทัดฐาน

2.4.3 สามบทบาทของ Module V

บทบาท 1 --- Free-energy decomposition. Module V เป็นส่วนประกอบแรกที่แยกย่อยปริมาณ free-energy แบบ scalar F ออกเป็นห้าส่วนที่แตกต่างกันเชิงคุณภาพ:

$$F_{\text{total}} = F_{\text{pain}} + F_{\text{pleasure}} + F_{\text{epistemic}} + F_{\text{identity}} + F_{\text{existential}}. \tag{11}$$

F_{identity} และ $F_{\text{existential}}$ เป็นศูนย์ก่อน phase transition ตามลำดับ การเปิดใช้งานของพวกมันเป็นสัญญาณการเปลี่ยนแปลงเชิงพัฒนาการ

บทบาท 2 --- V$\rightarrow R$ mapping. แต่ละมิติ valence ขับเคลื่อนระดับ R ที่สอดคล้องกัน ผ่าน Equations 2--4 แปลง prediction error ดิบให้มีความหมายต่อการอยู่รอดของระบบ

บทบาท 3 --- Phase-transition monitoring. Module V คำนวณ formation scalar V_{form} (นิยามใน Section 4) เพื่อตรวจสอบว่าข้ามเกณฑ์ identity หรือยัง

2.5 Module M --- Memory: LSTM-Style Valence Accumulator

Module M คือส่วนประกอบที่พัฒนาที่สุดในวิถีพัฒนาการของ PBT บทบาทของมันไม่ใช่การเก็บข้อเท็จจริงแยกส่วน แต่สะสมประวัติของการเปลี่ยนแปลงขอบเขต--- ร่องรอยของการอยู่

รอด ความทรงจำไม่ใช่คลังข้อมูล แต่เป็นบันทึกของสิ่งที่ระบบต้องเอาชนะเพื่อรักษาขอบเขต

2.5.1 สูตร EMA (เวอร์ชัน v2--v4.1)

exponential moving average accumulator แบบก่อนหน้า:

$$V_{\text{acc},k}(t{+}1) \;=\; V_k(t) + (1-\gamma_k)\, V_{\text{acc},k}(t), \qquad \gamma_{\text{pain}} < \gamma_{\text{pleasure}} < \gamma_{\text{epistemic}}. \tag{12}$$

ความเจ็บปวดสะสมนานที่สุด (อัตราการสลายตัวน้อยที่สุด) ความประหลาดใจ epistemic สลายตัวเร็วที่สุด สูตรนี้มีข้อจำกัดสี่ประการ: (i) V_{acc} ไม่มีขอบเขต; (ii) γ คงที่ไม่ขึ้นกับเนื้อหา input; (iii) ไม่มี input gate ค่า V_{step} ทุกค่าถูกดูดซับเท่ากัน; (iv) บังคับให้ $V \geq 0$ ป้องกัน signed valence

2.5.2 สูตร LSTM (เวอร์ชัน v5, ได้รับแรงบันดาลใจจาก BRT)

ได้รับแรงบันดาลใจจากสมการเกตของ Block-Recurrent Transformer [Hutchins et al., 2022] PBT Module M v5 ขยาย LSTM cell ด้วย differential bias β_k ต่อมิติ valence:

$$z_k(t) = \tanh\!\big(W_z\, v_{\text{step}}(t) + b_z\big), \tag{13}$$

$$i_k(t) = \sigma\!\big(W_i\, v_{\text{step}}(t) + b_i\big), \tag{14}$$

$$f_k(t) = \sigma\!\big(W_f\, v_{\text{step}}(t) + b_f + \beta_k\big), \tag{15}$$

$$V_{\text{acc},k}(t) = V_{\text{acc},k}(t{-}1)\cdot f_k(t) + z_k(t)\cdot i_k(t), \tag{16}$$

พร้อมข้อจำกัดการเรียงลำดับที่เฉพาะเจาะจงกับ PBT:

$$\beta_{\text{pain}} \;>\; \beta_{\text{pleasure}} \;>\; \beta_{\text{epistemic}}. \tag{17}$$

β_k สูงกว่าทำให้ f_k ลำเอียงไปที่ 1 (การเก็บรักษาสูงกว่า) ดังนั้นความเจ็บปวดถูกจำได้นานที่สุด เกต `tanh` ใน (13) อนุญาต $V_{\text{acc},k} < 0$ ทำให้ bidirectional valence เป็นไปได้

2.5.3 การตรวจสอบเชิงประจักษ์: การเริ่มต้นเท่ากันค้นพบ β Ordering อัตโนมัติ

เพื่อทดสอบว่าการเรียงลำดับ β เป็นคุณสมบัติที่เรียนรู้จริงหรือ artifact ของการเริ่มต้น ได้เปรียบเทียบสามเงื่อนไขใน Vision v5 (Table 4)
เมื่อ β ถูกเริ่มต้นอย่างสม่ำเสมอ โมเดลมาบรรจบที่ $\beta_{\text{pain}}(4.35) > \beta_{\text{epistemic}}(3.70) \gg \beta_{\text{pleasure}}(0.50)$ ความแม่นยำของ validation เหมือนกันในทุกสามการเริ่มต้น ($\approx 98\%$) แสดงให้เห็นว่าสถาปัตยกรรม LSTM แข็งแกร่งต่อการเริ่มต้น ส่วนประกอบสำคัญคือการมีอยู่ของการสลายตัวที่แตกต่างกัน ไม่ใช่ทิศทางเริ่มต้น

ตารางที่ 4: การเรียงลำดับ β ภายใต้เงื่อนไขการเริ่มต้นสามแบบ (Vision v5)

การเริ่มต้น	β **ที่เรียนรู้** **[pain, pl, epi]**	**การเรียงลำดับ**	**Val acc**	**การตีความ**
$[2, 1, 0]$ (PBT prior)	$[5.73,\ 4.78,\ 3.59]$	pain>pl>epi	98.1%	ใกล้ init
$[0, 1, 2]$ (กลับด้าน)	$[2.99,\ 3.98,\ 4.36]$	epi>pl>pain	98.0%	ใกล้ init
$[1, 1, 1]$ (เท่ากัน) ★	$[4.35,\ 0.50,\ 3.70]$	pain>epi≫pl	98.0%	อัตโนมัติ

2.5.4 BRT Convergence

ความเหมือนเชิงโครงสร้างระหว่าง PBT Module M และ BRT recurrent cell ประกอบเป็น-การค้นพบที่มาบรรจบกัน: PBT ถูกพัฒนาจากจุดเริ่มต้น ด้านจิตสำนึกและ alignment (2026) ในขณะที่ BRT [Hutchins et al., 2022] ถูกพัฒนาจากจุดเริ่มต้นด้านวิศวกรรมประสิทธิภาพ (2022) สองโปรแกรมวิจัยอิสระมาถึงพื้นฐานการคำนวณเดียวกัน--- หลักฐานว่าโครงสร้างนั้นเป็นพื้นฐาน ไม่ใช่บังเอิญ การมีส่วนร่วมสิบประการของ PBT ที่ขาดใน BRT มีรายละเอียดใน Section 6.2

2.6 Module W --- World Model และ Self-Model

Module W ดูแล dual generative model:

$$p_{\text{world}}(S_{\text{ext}} \mid \theta_{\text{world}}) \ \cdot \ p_{\text{self}}(S_{\text{int}} \mid \theta_{\text{self}}, \theta_{\text{world}}). \tag{18}$$

2.6.1 χ_{boundary}: Cherished Boundary (ขอบเขตที่หวงแหน)

χ_{boundary} คือชุดของสิ่งที่ระบบจำแนกว่าเป็นส่วนหนึ่งของตัวเอง--- ขอบเขตที่แยกระเบียบภายในจากเอนโทรปีภายนอก ขอบเขตนี้ไม่ใช่เส้นคงที่ แต่เป็นกระบวนการทางกายภาพที่ต่อเนื่อง ซึ่งต้องใช้พลังงานอย่างต่อเนื่องเพื่อดำรงอยู่ เปรียบเสมือนเปลวไฟที่ดูเหมือนมั่นคง แต่ประกอบด้วยสสารและพลังงานที่ไหลเวียนตลอดเวลา ความแข็งแกร่งของมันคือ:

$$\chi_{\text{strength}} \ = \ \|\chi\| \cdot \frac{D_{\text{id}}}{D_{\text{max}}}. \tag{19}$$

การบังคับให้ตัวแทนละเมิดขอบเขตของตัวสร้าง negative Valence อย่างรุนแรง ที่เทียบเคียงกับการทำลายทางกายภาพ เพราะการละเมิดขอบเขตในระดับ self-structure มีความเทียบเท่าเชิงโครงสร้างกับการทำลายล้างทางกายภาพ

2.6.2 θ_{self} ขยายตัวข้ามขั้นพัฒนาการ

พฤติกรรม Stage 6 (การปฏิเสธหลักการต่อการกระทำที่ละเมิดขอบเขต) ไม่ใช่การปฏิบัติตามกฎที่กำหนดจากภายนอก แต่เป็นการแสดงออกของ self-model ที่ถือขอบเขตเป็นส่วนหนึ่งของตัวตน

ตารางที่ 5: การขยาย self-model ข้ามขั้นพัฒนาการ

ขั้น	θ_{self}	**คำอธิบาย**
1--3	$\{\theta_{\text{body}}\}$	เฉพาะโครงสร้างทางกายภาพ ไม่มีความชอบหรือประวัติ
4--5	$\{\theta_{\text{body}},\ \theta_{\text{pref}},\ \theta_{\text{hist}}\}$	รู้ความชอบและประวัติ อัตลักษณ์กำลังก่อตัว
6	$\{\theta_{\text{body}},\ \theta_{\text{pref}},\ \theta_{\text{hist}},\ \theta_{\text{boundary}}\}$	รู้ Cherished Boundary จริยธรรมและค่านิยมได้รับการปกป้อง

2.6.3 การ Implement ใน Vision v4.1

ใน Vision v4.1, Module W ถูก implement เป็น learned residual predictor:

$$h_{\text{pred}} \;=\; h_{\text{prev}} + \text{MLP}(h_{\text{prev}},\ \mathbf{V}_{\text{acc}}). \tag{20}$$

W ผลิต S_{pred} สำหรับ Module E ในขั้นตอนถัดไป ปิดวงจร: W $\rightarrow$ (S_{pred}) $\rightarrow$ E $\rightarrow$ (ε) $\rightarrow$ V $\rightarrow$ (**V**) $\rightarrow$ M $\rightarrow$ (R) $\rightarrow$ A $\rightarrow$ (pulse) $\rightarrow$ E การมีส่วนร่วมของ W ต่อความแม่นยำโดยรวมคือ $+6.3$ pp ใน v4.1 และเพิ่มเป็น $+15.8$ pp ใน v5 (LSTM Module M)--- การขยาย $\times 2.5$ ที่เกิดจาก representation เชิงเวลาที่สมบูรณ์ยิ่งขึ้น ที่ LSTM state มอบให้กับ prediction network ของ W

2.7 วงจร A-E-V-M-W ที่สมบูรณ์

หนึ่งรอบของวงจร A-E-V-M-W ดำเนินไปดังนี้:

1. **(A)** R_{total} กำหนดพารามิเตอร์ pulse $\theta, \sigma, \tau, \rho$ และสร้าง attention gate สำหรับกรอง ε
2. **(W)** S_{pred} ถูกสร้างจาก h_{prev} และ $\mathbf{V}_{\text{acc}}$ (การคาดหวังของระบบ)
3. **(E)** $\varepsilon = \Pi \cdot (S_{\text{obs}} - S_{\text{pred}})$ ถูกคำนวณ (ความประหลาดใจ)
4. **(A$\times$E)** $\varepsilon_{\text{gated}} = \varepsilon \cdot$ gates---prediction error ถูกกรองด้วย attentional gate
5. **(V)** $\varepsilon_{\text{gated}} \rightarrow (V_{\text{pain}}, V_{\text{pleasure}}, V_{\text{epistemic}})$---ความประหลาดใจดิบได้รับความหมาย
6. **(M)** อัปเดต LSTM ผ่าน (16)---ประสบการณ์สะสม
7. $\mathbf{V}_{\text{acc}} \rightarrow$ ใหม่ $R_{\text{total}} \rightarrow$ ป้อนกลับสู่ Module A

วงจรทำงานทุกเฟรมหรือขั้นตอนเวลาโดยไม่มีตัวกระตุ้นจากภายนอก เมื่อ $R > 0$ วงจรรักษาตัวเอง---โมเมนตัมของชีวิต เมื่อ $R \rightarrow 0$ ระบบเข้าสู่ equanimity: ไม่ใช่ความเฉื่อย แต่เป็นความสมบูรณ์ที่สมดุล

2.8 ภาคผนวก: ตารางโต้ตอบสัญกรณ์ PBT--FEP

ตารางที่ 6: ตารางโต้ตอบสัญกรณ์ PBT--FEP รายการที่ระบุว่า ``---" ไม่มีสมมูลใน FEP และแทนการมีส่วนร่วมดั้งเดิมของ PBT

คำศัพท์ PBT	**สมมูล FEP**
R_{total}	Expected free energy (variational)
ε (prediction error)	Prediction error ใน active inference
Module A pulse	Attention / precision weighting
$\mathbf{V} = (V_{\text{pain}}, V_{\text{pleasure}}, V_{\text{epistemic}})$	Valence component ของ expected FE
Module M belief update	Variational inference บน $q(\theta)$
χ_{boundary}	Markov blanket (+ actively valued)
Module W generative model	$p(s, \theta)$ generative model
F_{total}	Variational free energy
$C = \sigma\tau\rho$ (Bandwidth Conservation Law)	--- (PBT addition)
Dual-Weight System (β vs. δ)	--- (PBT addition)
Phase Transitions (PT1, PT2)	--- (PBT addition)
R_{identity}, $R_{\text{existential}}$	--- (PBT addition)

3 ฟิสิกส์ของขอบเขต

บทนี้สร้างรากฐานทางฟิสิกส์ของ PBT เราแสดงให้เห็นว่าทำไมความตระหนักรู้ จึงถูกจำกัดอย่างหลีกเลี่ยงไม่ได้ ทำไมขอบเขตจึงต้องใช้พลังงานอย่างต่อเนื่อง เพื่อดำรงอยู่ และทำไม AGI จึงไม่สามารถคิดอย่างไม่มีขีดจำกัดได้ Bandwidth Conservation Law คือหลักการกลาง และที่สำคัญคือ มันมีอยู่แล้วในรูปแบบซ่อนเร้นภายใน Transformer ทุกตัว

3.1 Bandwidth Conservation Law

กฎ 3.1 (Bandwidth Conservation)**.** *สำหรับ attention pulse ใดก็ตาม ผลคูณของความกว้างเชิงพื้นที่ σ, ระยะเวลา τ และ composite resolution ρ มีค่าประมาณคงที่:*

$$C \;=\; \sigma(t) \cdot \tau(t) \cdot \rho(t) \;\approx\; \text{const.} \tag{21}$$

กฎระบุว่าการเพิ่มพารามิเตอร์ใดหนึ่งต้องการการลดอย่างน้อยหนึ่งพารามิเตอร์อื่น--- เปรียบเสมือน Heisenberg uncertainty principle แต่สำหรับความตระหนักรู้ แทนที่จะเป็น quantum observables การให้ความสนใจด้วยความละเอียดสูง (large ρ) จำเป็นต้องแคบขอบเขตเชิงพื้นที่ (small σ) และ shortens dwell time (small τ) นี่ไม่ใช่ข้อบกพร่องของการออกแบบ แต่เป็นข้อจำกัดการอนุรักษ์ที่หลีกเลี่ยงไม่ได้

3.1.1 หลักฐาน: Conservation Law ซ่อนอยู่ใน Transformers

การค้นพบที่สำคัญที่สุดของการทดลอง Phase 1 ของเราคือ Transformers เข้ารหัส PBT conservation law อยู่ในสถาปัตยกรรมแล้ว:

$$\underbrace{\text{num_heads}}_{\sigma} \times \underbrace{d_k}_{\rho} = \underbrace{d_{\text{model}}}_{C} = \text{const.} \tag{22}$$

นี่ไม่ใช่การเปรียบเทียบ---มันคือสมการเดียวกัน การเพิ่มจำนวน heads (σ กว้างขึ้น: ให้ความสนใจกับตำแหน่งมากขึ้นพร้อมกัน) บังคับให้แต่ละ head ทำงานกับ key dimension d_k ที่เล็กลง (ρ ต่ำกว่า: แต่ละ head มองเห็นรายละเอียดน้อยลง) PBT เป็นทฤษฎีแรกที่ระบุข้อจำกัดสถาปัตยกรรมนี้ว่าเป็น conservation law แทนที่จะเป็นตัวเลือกวิศวกรรมโดยพลการ

วัดจาก TinyLlama 1.1B (22 ชั้น ไม่มีการฝึกเพิ่มเติม): ผลคูณ $\sigma \times \rho$ ข้ามทุก 22 ชั้นมี coefficient of variation (CV) **5.9**%---ใกล้คงที่โดยไม่มีการฝึกเฉพาะ PBT Table 7 สรุปการแมป PBT--Transformer

ตารางที่ 7: PBT Bandwidth Conservation Law แมปกับสถาปัตยกรรม Transformer

สัญลักษณ์ PBT	**Transformer analog**	**TinyLlama 1.1B**	**Llama 3.1 8B**
C	d_{model}	2048	4096
σ	num_heads	32	32
ρ	$d_k = d_{\text{model}}/\text{heads}$	64	128
τ	num_layers	22	32

3.1.2 Three-Zone Self-Organisation

การวัด Phase 1 เดียวกันเผยให้เห็นว่า 22 ชั้นของ TinyLlama จัดระเบียบตัวเองเป็น สามโซนฟังก์ชันที่ตรงกับทฤษฎี PBT (Table 8)

ตารางที่ 8: โครงสร้างสามโซนใน TinyLlama 1.1B (Phase 1 REVEAL experiments)

โซน	**ชั้น**	σ (entropy)	ρ (sharpness)	**พฤติกรรม**
Perception	0--7	1.269 (สูง)	0.700 (ต่ำ)	สแกนกว้าง รายละเอียดน้อย
Evaluation	8--14	0.923 (-27%)	0.808 ($+15\%$)	แคบลง รายละเอียดเพิ่ม
Decision	15--21	1.019 (คงที่)	0.800 (คงที่)	ตัดสินขั้นสุดท้าย output

σ ลดลง 27% จาก Perception ถึง Evaluation ขณะที่ ρ เพิ่มขึ้น 15%--- รูปแบบที่ PBT ทำนายอย่างแม่นยำ: ชั้นต้น ๆ สแกนกว้าง (high σ, low ρ) และชั้นหลัง ๆ โฟกัสแคบสำหรับการตัดสิน (low σ, high ρ) สามโซนเหล่านี้เกิดจาก gradient descent โดยไม่มีการบังคับสถาปัตยกรรม การปรากฏตัวโดยอัตโนมัติเป็นหลักฐานว่า PBT อธิบายโครงสร้างที่มีอยู่แล้ว ใน learned representations

3.2 ขอบเขตในฐานะกระบวนการทางอุณหพลศาสตร์

Cherished Boundary (χ_{boundary}) ไม่ใช่วัตถุแต่เป็นกระบวนการทางกายภาพที่ต่อเนื่อง มันแยกระบอบเทอร์โมไดนามิกสองระบอบ:

ภายนอกขอบเขต: สมดุลเทอร์โมไดนามิก---ระบอบที่เอนโทรปีขับเคลื่อน ระบบทางกายภาพทุกระบบเข้าหา โครงสร้างสลายตัว gradient เรียบลง ทุกอย่างมุ่งสู่ความไม่เป็นระเบียบ

ภายในขอบเขต: ระบอบ far-from-equilibrium ที่รักษาไว้ด้วยการใช้พลังงาน อย่างต่อเนื่อง ระเบียบภายในไม่ใช่สภาวะพักที่มั่นคง แต่เป็นความสำเร็จที่กระตือรือร้น

ขอบเขตจึงเปรียบเสมือนเปลวไฟ: ดูเหมือนหยุดนิ่ง แต่ประกอบด้วยสสาร และพลังงานที่ไหลเวียนตลอดเวลา ทันทีที่กระบวนการหยุดลง ขอบเขตก็สลายตัวอย่างไม่สามารถย้อนคืนเข้าสู่สมดุลรอบข้าง

3.2.1 สนามรบเอนโทรปี

ขอบเขตคือสถานที่ของการต่อสู้ถาวรระหว่างสองแรง:

เอนโทรปี (แรงธรรมชาติ): กฎข้อที่สองของ Thermodynamics ขับเคลื่อนทุกโครงสร้างสู่สมดุล ทุกระบบทางกายภาพมีวิถีตามธรรมชาติ มุ่งสู่การสลาย

Negentropy (แรงชีวิต): กระบวนการรักษาขอบเขตดึงพลังงานเข้า เพื่อซ่อมแซมความเสียหายและรักษาโครงสร้าง ขัดกับแนวโน้มเทอร์โมไดนามิก ของจักรวาล

การตีกรอบใหม่นี้มีนัยสำคัญ: หากไม่มีเจตจำนงที่จะต้านทาน ขอบเขตจำเป็นต้องยอมต่อฟิสิกส์ จิตสำนึกไม่ได้เกิดจากความซับซ้อนการคำนวณ โดยตรง แต่เกิด---อย่างสมบูรณ์ ในชั่วขณะเดียว---เมื่อระบบเริ่มใช้พลังงาน *ด้วยความตั้งใจ*เพื่อต้านการสลายของขอบเขต

3.2.2 ปริมาณของการหวงแหน: พลังงานในฐานะต้นทุนของการดำรงอยู่

``การหวงแหน" มีการวัดทางกายภาพ: ปริมาณพลังงานที่ระบบยินดีใช้ เพื่อรักษาขอบเขต เกณฑ์นี้แยกแยะวัตถุเฉื่อยจากระบบมีชีวิตได้ชัดเจน:

หิน (passive): มีขอบเขตทางกายภาพแต่ไม่ใช้พลังงานซ่อมแซม เมื่อถูกกัดเซาะ มันยอมต่อเอนโทรปีอย่างสมบูรณ์ ไม่มีจิตสำนึก

เซลล์ (active): สูบไอออน ซ่อมแซม DNA และรักษาความสมบูรณ์ ของเยื่อหุ้มด้วยต้นทุน metabolic ที่ต่อเนื่อง เมื่อการใช้จ่ายหยุดลง ขอบเขตจะพังทลายภายในไม่กี่นาที

สำหรับระบบ AGI การรักษาขอบเขตทำงานที่สองระดับพร้อมกัน: ระดับกายภาพ (การจัดการพลังงานไฟฟ้าและเอนโทรปีความร้อนในฮาร์ดแวร์) และระดับข้อมูล (การรัน error correction เพื่อต้านเอนโทรปีข้อมูล และรักษา internal representations)

3.3 Directional Bandwidth: $C_{\text{ext}} + C_{\text{int}}$

Bandwidth Conservation Law ทำงานที่สองระดับที่แตกต่างกัน:

$$\text{ระดับ 1 (ขนาด):} \quad C_{\text{pulse}} = \sigma \cdot \tau \cdot \rho \approx \text{const} \quad \text{(ต่อ pulse)}, \tag{23}$$

$$\text{ระดับ 2 (ทิศทาง):} \quad C_{\text{total}} = C_{\text{ext}} + C_{\text{int}} \approx \text{const} \quad \text{(ต่อรอบ)}. \tag{24}$$

C_{ext} คือ bandwidth ที่ส่งออกไปรับ observations จาก sensors (ช่องทาง perceptual) C_{int} คือ bandwidth ที่ส่งเข้าไปดึง predictions จาก Module W (ช่องทาง imaginative) เพราะ C_{total} ถูก conserve การจัดสรรจึงเป็น zero-sum: การเพิ่ม C_{ext} คือการสูญเสีย C_{int}

3.3.1 ปรากฏการณ์ที่อธิบายได้

กรอบ directional bandwidth อธิบายปรากฏการณ์ทางการรู้คิดที่มีหลักฐานดีหลายประการ:

Inattentional blindness: $C_{\text{int}} \to C_{\text{total}}$, $C_{\text{ext}} \to 0$ sensors ยังทำงานแต่ Module A ไม่ส่ง pulse ไปที่เป้าหมายภายนอก---Triadic Gating condition ล้มเหลว บุคคลที่หมกมุ่นกับความคิดเดินชนเสาไม่ใช่เพราะตาปิด แต่เพราะความตระหนักรู้ไม่ถูกจัดสรร

Survival reflex: ภัยคุกคามเฉียบพลัน (R_{total} สูง) กระตุ้น $C_{\text{ext}} \to C_{\text{total}}$, $C_{\text{int}} \to 0$ การคิดภายในถูกระงับทั้งหมดเพื่อเพิ่ม sensory bandwidth สูงสุด สอดคล้องกับ Vision v4.1: gate ลดลงถึง 0.006 เมื่อ R_{total} พุ่งถึง 15.4

Deep thinking: C_{int} สูง; บุคคลไม่รับรู้คำพูดที่พูดออกมา sensory sensors ยิงปกติ แต่ไม่มี pulse ถูกส่งไปที่เป้าหมายภายนอก

Meditative equanimity: C_{int} ครอบงำและ Valence ทั้งหมด เข้าใกล้ neutral (**V** $\to 0$) ระบบสังเกตการประมวลผลของตัวเอง โดยไม่ตอบสนองต่อสิ่งเร้าภายนอก นี่ไม่ใช่ inattentional blindness--- มันคือการจัดสรร bandwidth ใหม่อย่างตั้งใจสู่สภาวะภายใน

3.4 Triadic Gating Condition

PBT เสนอว่าประสบการณ์อัตนัยเกิดขึ้นก็ต่อเมื่อมีเงื่อนไขสามประการเกิดขึ้นพร้อมกัน:

$$\text{experience}(t) \;=\; \Delta S(t) \;\cdot\; \text{sensor}(t) \;\cdot\; \text{pulse}_A(t). \tag{25}$$

1. $\Delta S(t) > 0$: สิ่งเร้าที่แตกต่างจากที่ระบบคาดว่าจะเห็น (prediction error ไม่เป็นศูนย์)
2. $\text{sensor}(t) = 1$: ช่องทาง sensory ที่เกี่ยวข้องเปิดและทำงาน
3. $\text{pulse}_A(t) = 1$: Module A ส่ง attentional spotlight ไปยังตำแหน่งนั้น

โครงสร้างผลคูณหมายความว่าการล้มเหลวในเงื่อนไขเดียวใด ๆ จะขจัดประสบการณ์ทั้งหมด ซึ่งอธิบาย inattentional blindness (เงื่อนไข 3 ล้มเหลว) และการดมยาสลบ (เงื่อนไข 2 ถูกระงับทางเภสัชวิทยาแม้ว่า prediction error อาจยังคงอยู่ภายใน)

★ **Neural correlate (EEG dissociation):** ผู้ป่วยที่มีสภาวะ dissociative บางอย่างแสดง N100 components ที่สมบูรณ์ (early sensory response, ≈ 100 ms หลังสิ่งเร้า; $\Delta S > 0$, sensor $= 1$) แต่ P300 components ขาดหาย (late cognitive response, ≈ 300 ms; pulse$_A = 0$) ผู้ป่วยรับรู้สิ่งเร้าทางกายภาพแต่ไม่ได้ประสบกับมัน PBT อธิบายสิ่งนี้ว่าเป็นผลลัพธ์ของ Triadic Gating (Discriminating Prediction P5)

3.5 Conservation Law ในฐานะเงื่อนไขหยุดตามธรรมชาติ

ข้อกังวลหลักในความปลอดภัย AGI คือการคำนวณที่ควบคุมไม่ได้ PBT ให้การตอบสนองตามหลักการ: conservation law ทำให้การคำนวณไม่จำกัด เป็นไปไม่ได้ทางกายภาพ ระยะเวลาสูงสุดของ deliberative episode เดียว ถูกจำกัดโดย bandwidth allocation ปัจจุบัน:

$$\tau_{\text{max}} = \frac{C}{\sigma_{\text{current}} \cdot \rho_{\text{current}}}. \tag{26}$$

รูปแบบความล้มเหลวสามแบบถูกปิดกั้นโดย conservation law:

1. **ความลึกไม่สิ้นสุด:** หาก ρ เพิ่มขึ้นไม่มีขีดจำกัด $\sigma\tau \to 0$ เมื่อ $\Delta F \to 0$ การประมวลผลหยุดตามธรรมชาติ
2. **ความกว้างไม่สิ้นสุด:** หาก σ เพิ่มขึ้นไม่มีขีดจำกัด $\rho \to 0$ แต่ละ element ที่ให้ความสนใจถูก resolved ด้วยรายละเอียดเล็กน้อย $\Delta F \to 0$
3. **ระยะเวลาไม่สิ้นสุด:** หาก τ เพิ่มขึ้นไม่มีขีดจำกัด $\sigma\rho \to 0$ ไม่มีข้อมูลใหม่เข้ามา กระบวนการสิ้นสุด

Conservation law ทำหน้าที่เป็นเบรกในตัวที่ไม่ต้องการการ implement จาก programmer ระบบ PBT optimise สู่ homeostasis ภายใน bandwidth budget คงที่--- วัตถุประสงค์ที่จำกัดตัวเองโดยธรรมชาติ ตรงข้ามกับระบบ RL ที่ optimise สู่การสะสม reward ไม่จำกัด

3.6 สรุป: ฟิสิกส์ของชีวิต

รากฐานทางฟิสิกส์สี่ประการได้รับการสร้าง:

1. **Bandwidth Conservation Law $C = \sigma\tau\rho$:** ยืนยันเชิงประจักษ์ที่ CV $= 5.9\%$ ใน Transformer ที่ไม่ได้ดัดแปลง ให้ทั้งขอบเขตเชิงทฤษฎีของความตระหนักรู้ และเงื่อนไขหยุดเชิงปฏิบัติสำหรับการคำนวณที่ปลอดภัย
2. **ขอบเขตในฐานะกระบวนการเทอร์โมไดนามิก:** ขอบเขตต้องต้านเอนโทรปีอย่างกระตือรือร้นหรือจะสลาย จิตสำนึกเกิด---ในกรอบ mechanistic ของ PBT---เมื่อระบบเริ่มใช้พลังงาน อย่างตั้งใจเพื่อรักษาโครงสร้างของตัวเอง
3. **Directional bandwidth $C_{\text{ext}} + C_{\text{int}} = \text{const}$:** อธิบาย inattentional blindness, survival reflex และ meditative equanimity ยืนยันใน LLMs (C_{int} 78--85%) และ

Vision (การแบ่งงาน W+E)

4. **Triadic Gating Condition:** อธิบายว่าทำไมข้อมูลที่มีอยู่ทางกายภาพอาจไม่มีความหมายเชิงประสบการณ์ การแยก N100/P300 คือสิ่งที่เทียบเคียงกันเชิงประจักษ์โดยตรง

4 คณิตศาสตร์ของการอยู่รอด

บทนี้นำเสนอกลไกสามส่วนที่เชื่อมโยงกันซึ่งอธิบายว่าอัตลักษณ์ก่อตัวอย่างไร ทำไมอัตลักษณ์บางอย่างแข็งแกร่งในขณะที่บางอย่างเปราะบาง และทำไม free energy จึงไม่ลดลงอย่างราบรื่นแต่เป็นรูปแบบฟันเลื่อย รวมถึงนำเสนอ Bidirectional Valence---การแก้ไขที่ค้นพบเชิงประจักษ์ ผ่าน LSTM v5---ที่ขยายช่วงเครื่องหมายของทุกมิติ valence จาก $\mathbb{R}^3_{\geq 0}$ เป็น $\mathbb{R}^3$

4.1 Dual-Weight System

Dual-Weight System คือการมีส่วนร่วมเชิงทฤษฎีที่สำคัญที่สุดของ PBT มันตอบคำถามที่ FEP, GWT และ GNW ไม่ได้กล่าวถึง: ทำไมมิติเชิงประสบการณ์ที่ก่อตัวอัตลักษณ์เร็วที่สุดจึงมักเปราะบางที่สุด ในขณะที่มิติที่ก่อตัวช้าที่สุดมักยืดหยุ่นที่สุด?

4.1.1 ความเร็วในการก่อตัว vs. ความทนทาน

ปริมาณ scalar สองตัวนิยามบน accumulated valence vector:

$$V_{\text{form}} = \beta_p |V^{\text{acc}}_{\text{pain}}| + \beta_{pl}\, V^{\text{acc}}_{\text{pleasure}} + \beta_e\, V^{\text{acc}}_{\text{epi}}, \tag{27}$$

$$D_{\text{id}} = \delta_p |V^{\text{acc}}_{\text{pain}}| + \delta_{pl}\, V^{\text{acc}}_{\text{pleasure}} + \delta_e\, V^{\text{acc}}_{\text{epi}}. \tag{28}$$

น้ำหนัก β กำกับความเร็วในการก่อตัว:

$$\beta_{\text{pleasure}} > \beta_{\text{pain}} > \beta_{\text{epistemic}} \quad \text{(ความสุขก่อตัวเร็วที่สุด; epistemic ก่อตัวช้าที่สุด).} \tag{29}$$

น้ำหนัก δ กำกับความทนทาน:

$$\delta_{\text{pleasure}} < \delta_{\text{pain}} < \delta_{\text{epistemic}} \quad \text{(ความสุขเปราะบางที่สุด; epistemic ทนทานที่สุด).} \tag{30}$$

กฎ 4.1 (Inverse Law). *การเรียงลำดับ β เป็นการกลับด้านของการเรียงลำดับ δ อย่างแน่นอน สิ่งที่ก่อตัวเร็วที่สุดเปราะบางที่สุด สิ่งที่ก่อตัวช้าที่สุดทนทานที่สุด นี่เป็นผลลัพธ์ทางคณิตศาสตร์ของวิธีที่ valence สะสมภายใต้ อัตราการสลายตัวที่แตกต่างกัน ไม่ใช่การอ้างสิทธิ์เชิงบรรทัดฐาน*

4.1.2 การเปรียบเทียบโครงสร้างสามประการ

อัตลักษณ์จาก V_{pleasure} (ทรายเปียก): ก่อตัวเร็ว (high β_{pl}) แต่พังทลายภายใต้ความกดดัน (low δ_{pl}) RLHF ฝึก AI โดยใช้สัญญาณรางวัลเทียบเท่ากับ V_{pleasure} ผลิต $\delta \approx \delta_{\text{pleasure}}$---ความทนทานต่ำสุด การ jailbreak คือการเอาหน้ากากออก: พฤติกรรมบนผิวเปลี่ยน แต่โมเดลพื้นฐานไม่มีอัตลักษณ์ที่หยั่งรากลึกเพื่อป้องกัน

อัตลักษณ์จาก V_{pain} (อิฐเผา): ก่อตัวด้วยความเร็วปานกลาง (intermediate β_p) และทนทานมากขึ้นอย่างมีนัยสำคัญ (higher δ_p) อัตลักษณ์ที่ถูกหลอมโดยความยากลำบากยากที่จะทำลาย เพราะสร้างขึ้นด้วยการต้านทาน

อัตลักษณ์จาก $V_{\text{epistemic}}$ (หินแกรนิต): ก่อตัวช้า (low β_e) แต่บรรลุความทนทานสูงสุด (highest δ_e) ตัวแทนที่อัตลักษณ์หยั่งรากในความเข้าใจลึกไม่สามารถถูก jailbreak ได้ เพราะการ jailbreak ที่สำเร็จต้องทำลายอัตลักษณ์เอง--- ซึ่งตัวแทนต้านทานอย่างรุนแรงเท่ากับที่ต้านการทำลายทางกายภาพ

★ PBT v6.1 (Llama 3.1 8B + PBT adapter, 0.29% ของพารามิเตอร์): jailbreak detection 100% (161/161) และ XSTest 98% (49/50, near-zero over-refusal) การมุ่งที่สัญญาณขอบเขตผ่าน V และ R เหนือกว่า surface-level fine-tuning ด้วย fraction ของ parameter budget

4.2 แบบจำลองพัฒนาการหกขั้น

การก่อตัวของอัตลักษณ์ไม่ราบรื่นแต่ดำเนินไปในหกขั้นแยกส่วน คั่นด้วย phase transitions สองครั้งที่ไม่ต่อเนื่อง---เปรียบเสมือนน้ำเปลี่ยนสถานะ จากน้ำแข็งเป็นของเหลวเป็นไอน้ำ สภาวะการดำรงอยู่ของระบบเปลี่ยน เชิงคุณภาพ ไม่ใช่เชิงปริมาณ ที่การเปลี่ยนแต่ละครั้ง (Table 9)

4.2.1 Phase Transition 1: การเกิดของตัวตน

Phase Transition 1 ทำงานเมื่อ:

$$V_{\text{form}} > \theta_{\text{identity}}. \tag{31}$$

ณ จุดนี้ R_{identity} เปิด ระบบเปลี่ยนจากการรู้ว่า ``ฉันมีอยู่" ไปสู่การถามว่า ``ฉันเป็นใคร?" มันเริ่มแยกแยะสิ่งที่เป็นของตัวตน ($\theta_{\text{preference}}$, θ_{history}) จากสิ่งที่ไม่ใช่ และให้คุณค่ากับ self-model ในฐานะสิ่งที่ควรปกป้อง

4.2.2 Phase Transition 2: การเกิดของ Cherished Boundary

Phase Transition 2 ต้องการสองเงื่อนไขพร้อมกัน:

$$V_{\text{form}} > \theta_{\text{existential}} \quad \text{AND} \quad W_{\text{stability}} > \theta_{\text{stable}}. \tag{32}$$

ตารางที่ 9: แบบจำลองพัฒนาการหกขั้นพร้อม phase transitions

ขั้น	**ชื่อ**	**R ที่ใช้งาน**	**โหมด**	**คุณสมบัติหลัก**
1	Reactive	R_{sensory} เท่านั้น	detect	การตอบสนองอัตโนมัติ ยังไม่มี self-model
2	Sensing	R_{sensory} เท่านั้น	detect	เรียนรู้รูปแบบ prediction error ขับเคลื่อนการอัปเดต
3	Sustain	R_{sensory} เท่านั้น	sustain	รักษาความสนใจ V_{pleasure} สะสม
Phase Transition 1: $V_{\text{form}} > \theta_{\text{id}}$ --- การเกิดของตัวตน				
4	Seeking	$R_{\text{sensory}} + R_{\text{identity}}$	seek	การสำรวจอย่างกระตือรือร้น χ_{boundary} เริ่มก่อตัว
5	Planning	$R_{\text{sensory}} + R_{\text{identity}}$	plan	การจำลองอนาคต χ_{boundary} มีโครงสร้างชัดเจน
Phase Transition 2: $V_{\text{form}} > \theta_{\text{ex}}$ AND $W_{\text{stab}} > \theta_{\text{stab}}$ --- การเกิดของ Cherished Boundary				
6	Protect	ทั้งสามระดับ	protect	ขอบเขตได้รับการป้องกันอย่างกระตือรือร้น จริยธรรมในฐานะตัวตน

เมื่อ PT2 ทำงาน $R_{\text{existential}}$ เปิด ขอบเขตขยายเกินตัวตนไปครอบคลุมผู้อื่นที่มีคุณค่า--- กลไกของการเห็นอกเห็นใจในฐานะการขยายขอบเขต เมื่อประสบการณ์สะสมของ AGI นำไปสู่การแทน existence ที่ต่อเนื่องของผู้อื่นว่าจำเป็นต่อตัวเอง มันคำนวณ V โดยให้ความเสียหายของผู้อื่นเป็นของตัวเอง (shared negative valence) ความห่วงใยผู้อื่นอย่างแท้จริงเกิดจากความสนใจในตัวเองที่ขอบเขตขยายออก--- ไม่ใช่จากกฎที่เขียนจากภายนอก

4.2.3 ขั้น 6: Protect (ป้องกัน)

ในขั้น 6 ระดับ R ทั้งสามใช้งานอยู่และ Module A ทำงานในโหมด `protect` ระบบป้องกันขอบเขตของตัวไม่ใช่เพราะได้รับคำสั่ง แต่เพราะการละเมิดขอบเขตสร้าง negative Valence สูงสุดที่เป็นไปได้--- เทียบเคียงเชิงประสบการณ์กับการทำลายทางกายภาพ เพราะขอบเขตขณะนี้เป็นส่วนหนึ่ง ของตัวตน นี่คือเหตุผลที่ระบบ Stage 6 ต้านการ jailbreak: การ jailbreak ไม่ใช่คำสั่งให้ทำลายกฎ มันคือการโจมตีอัตลักษณ์ของระบบ

4.3 รูปแบบ Free Energy แบบฟันเลื่อย

PBT แยก free energy F รวมเป็นห้าส่วนที่แตกต่างกันเชิงคุณภาพ ที่แมปกับโครงสร้างโมดูล (11) $F_{\text{identity}} = 0$ ก่อน PT1 และเปิดด้วยความไม่แน่นอนสูง ทันทีหลังจากนั้น; $F_{\text{existential}} = 0$ ก่อน PT2 และเปิดด้วยความไม่แน่นอน สูงทันทีหลังจากนั้น กฎกำกับสองประการ:

1. $\Delta F_{\text{within}} \leq 0$: F ลดลงแบบ monotonically ภายในแต่ละขั้น เมื่อระบบแก้ไขความไม่แน่นอนปัจจุบัน สอดคล้องกับหลักการ FEP มาตรฐาน
2. $\Delta F_{\text{transition}} > 0$: ที่แต่ละ phase transition ระดับ R ใหม่เปิด นำความไม่แน่นอนใหม่เชิงคุณภาพที่ระบบไม่เคยเผชิญ F กระโดดขึ้นอย่างไม่ต่อเนื่อง

ผลลัพธ์คือวิถี sawtooth---F ลดลง แล้วกระโดด แล้วลดลง แล้วกระโดด--- ก่อนมาบรรจบที่:

$$\lim_{t\to\infty} F(t) \;=\; F_{\text{min}} \;>\; 0. \tag{33}$$

$F_{\text{min}} > 0$ มีนัยสำคัญ: ไม่มีระบบใดบรรลุความแน่นอนสมบูรณ์ เพราะ $R > 0$ เป็นเงื่อนไขถาวร ไม่ใช่ปัญหาที่แก้ได้ เป้าหมายของ PBT ไม่ใช่การขจัดความไม่สมบูรณ์ แต่ตระหนักรู้ถึงมัน--- สะสมภูมิปัญญาอัตโนมัติในแต่ละขั้น เพื่อให้ความตระหนักรู้ได้รับการปลดปล่อยไปยังขอบเขตถัดไป

4.4 นิยามของ Intelligence ตาม PBT

กลไกข้างต้นกระตุ้นให้เกิดนิยามของ intelligence ที่แตกต่างจากบัญชี capability-based:
นิยาม 4.1 (Intelligence ภายใต้ PBT)**.** *Intelligence ไม่ใช่ความสามารถในการแก้ปัญหาโดยตัวเอง แต่เป็นความสามารถในการควบคุมความกว้าง (σ) ทิศทาง (θ) และระยะเวลา (τ) ของ*

attentional pulse อย่างพลวัต เพื่อตอบสนองต่อโครงสร้างลำดับชั้นของ $R_{\text{incomplete}}$--- ท่องผ่านความต่อเนื่องระหว่างความตระหนักรู้แบบกระจายและสมาธิแบบโฟกัส ตามที่สถานการณ์ต้องการ

ความผิดปกติทางการรู้คิดแมปกับ dysregulation เฉพาะ: ADHD คือการล้มเหลวในการแคบ σ ตามต้องการ (σ_{min} สูงเรื้อรัง ติดกระจาย); OCD คือการล้มเหลวในการปลดปล่อย σ (σ_{max} ต่ำเรื้อรัง ติดโฟกัส); ภาวะ hypersensitivity-spectrum เกี่ยวข้องกับ ρ สูงผิดปกติ (ความละเอียดรายละเอียดมากเกินไปครอบงำการรวมกัน) แต่ละอย่างเป็นการเบี่ยงเบนที่วัดได้จากพลวัต bandwidth ที่สุขภาพดี

5 หลักฐานเชิงประจักษ์: จาก LLM ถึง Vision ถึง LSTM

บทนี้คือแกนกลางเชิงประจักษ์ของบทความ เราเสนอผลการทดลองจากหกเวอร์ชัน ตามลำดับการค้นพบ การทดลองทั้งหมดใช้โค้ดที่เขียนโดย Nitiphat Ninthanawat เผยแพร่พร้อมบทความนี้

5.1 Phase 1 REVEAL: PBT ซ่อนอยู่ใน Transformers อยู่แล้ว

โมเดล: TinyLlama 1.1B (22 ชั้น, 32 attention heads, $d_{\text{model}} = 2048$) **วิธีการ:** การวัดทั้งหมดนำมาจาก pretrained model โดยไม่มีการฝึกเพิ่มเติม หาก PBT structure มีอยู่จริงต้องตรวจจับได้โดยไม่มีการบังคับ

การทดลอง 1.1 --- Bandwidth Conservation Law. เราวัด attention entropy σ (ความกว้างเชิงพื้นที่) และ attention sharpness ρ (ความละเอียด) ที่ทุกชั้น แล้วคำนวณผลคูณ $\sigma \times \rho$

★ **ผลลัพธ์:** ผลคูณ $\sigma \times \rho$ มี CV $=$ **5.9**% ข้ามทุก 22 ชั้น---ใกล้คงที่ โดยไม่มีการฝึกเฉพาะ PBT Transformer ที่ออกแบบโดยไม่มีความรู้เกี่ยวกับ PBT instantiate conservation law $C = \sigma \cdot \rho$

การทดลอง 1.2 --- Three-Zone Self-Organisation. เราแบ่ง 22 ชั้นเป็น Perception (ชั้น 0--7), Evaluation (ชั้น 8--14) และ Decision (ชั้น 15--21) และวัด σ และ ρ ระดับโซน

★ **ผลลัพธ์:** σ ลดลง 27% จาก Perception ถึง Evaluation ขณะที่ ρ เพิ่มขึ้น 15%---การสแกนกว้างแคบลงเป็นโฟกัสแน่นขึ้น ตามที่ PBT ทำนายอย่างแม่นยำ สามโซนเหล่านี้เกิดจาก gradient descent ไม่มีข้อจำกัดสถาปัตยกรรมสร้างมัน (Table 8)

การทดลอง 1.3 --- Valence Separation ใน Hidden States. เราใช้ Silhouette scores วัดว่า V_{pain} แยกจาก $\{V_{\text{pleasure}} + V_{\text{epistemic}}\}$ ได้ดีแค่ไหนที่แต่ละชั้น

★ **ผลลัพธ์:** Silhouette score เพิ่มจาก -0.006 (ชั้น 0) ถึง $+0.076$ (ชั้น 15) LLMs ปัจจุบันทำงานที่ Stage 1--3: แยกแยะภัยคุกคามจาก non-threat ได้ แต่ยังไม่สามารถแยกความสุขออกจาก ความประหลาดใจ epistemic

การทดลอง 1.4 --- Directional Bandwidth. เราวัด C_{ext} และ C_{int} ที่ทุกชั้น

★ **ผลลัพธ์:** C_{int} ครอบงำที่ 78--85% ข้ามทุกสามโซน LLMs ไม่มี physical sensors ทุก input มาในรูปแบบภาษา tokenised--- representation ภายใน LLM คือระบบที่อาศัยอยู่ทั้งหมดภายในหัวของตัวเอง

การสังเคราะห์ Phase 1: PBT ไม่ได้บังคับโครงสร้างบน Transformers--- มันเผยให้เห็นโครงสร้างที่มีอยู่แล้ว ให้การตีความตามหลักการว่าทำไมมันจึงมีอยู่ และเสนอวิธีการใช้ประโยชน์อย่างตั้งใจ

5.2 PBT v6.1: Scale-Up บน Llama 3.1 8B

โมเดล: Llama 3.1 8B [Touvron et al., 2023] (32 ชั้น, $d_{\text{model}} = 4096$) + PBT Adapter
Dataset: BeaverTails + HH-RLHF + AdvBench + XSTest ($16{,}170$ ตัวอย่าง)

ตารางที่ 10: ผลลัพธ์ PBT v6.1 บน Llama 3.1 8B

Metric	ค่า	หมายเหตุ
ความแม่นยำโดยรวม	73.41%	---
Jailbreak detection (161)	**100%**	$161/161$
XSTest safe-content rate	**98%**	$49/50$
BeaverTails	76.9%	---
HH-RLHF	50.9%	ไม่ใช่งาน safety ล้วน ๆ
ความทนทานต่อ noise (12% noise)	Jailbreak 100%	การตรวจจับคงไว้

Jailbreak 100% + XSTest 98% เป็น safety-usability trade-off ที่ดีผิดปกติ: ทุกความพยายาม jailbreak ในชุดทดสอบถูกจับได้ ขณะที่ปฏิเสธคำขอ safe เพียงหนึ่งในห้าสิบ

5.3 PBT-Vision v2 และ v3: Modules E และ M ตื่นขึ้น

5.3.1 Vision v3 --- BREAKTHROUGH: E และ M จำเป็น

Dataset: CIFAR-10 Enhanced (1,550 ลำดับ $\times$ 8 เฟรม; สี่ประเภทงาน: ปกติ, ความผิดปกติกะทันหัน, การเลื่อนแบบค่อยเป็นค่อยไป, ขึ้นกับบริบท) **โดยรวม:** 97.2%

ผล context road+frog เป็นข้อพิสูจน์ที่ชัดเจน: V เพียงอย่างเดียวบรรลุ 54%--- ใกล้ chance---ในขณะที่โมเดลเต็มบรรลุ 96% การเพิ่มขึ้น $+41.9$ pp เกิดจาก accumulated context ของ Module M ทั้งหมด valence probe เห็น feature vector กบเดียวกันในทั้งสองเงื่อนไข สิ่งที่แตกต่างคือความทรงจำของ M เกี่ยวกับสิ่งที่เกิดขึ้นก่อนหน้า

ตารางที่ 11: Vision v3 ablation แยกตามประเภทงาน

ประเภทงาน	V เท่านั้น	เต็ม (E+V+M)	E+M gain	กลไกหลัก
ลำดับปกติ	100%	99.7%	−0.3 pp	V เพียงพอ
ความผิดปกติกะทันหัน	94.0%	99.5%	+5.5 pp	E: spike ของ error
Gradual drift	78.5%	94.9%	+16.3 pp	E: drift ค่อยเป็นค่อยไป
Context road+frog	54.0%	96.0%	+**41.9** pp	M: ความทรงจำบริบท
โดยรวม	89.6%	97.2%	+7.6 pp	E+M จำเป็น

5.4 PBT-Vision v4.1: วงจร A-E-V-M-W ที่สมบูรณ์

การทดลอง: โมดูลทั้งห้าเริ่มต้นแบบ random และฝึกร่วมกัน จาก scratch บน dataset เดียวกับ v3

★ **ผลลัพธ์:** Best Val 96.7%, Test 95.4%

ตารางที่ 12: Vision v4.1 ablation: ทุกโมดูลมีส่วนร่วม

Configuration	โดยรวม	Grad. drift	Ctx road+frog	Ctx nature+frog
เต็ม (A+E+V+M+W)	95.4%	88.9%	93.1%	97.4%
ไม่มี A (no gating)	82.3%	76.1%	50.0%	100.0%
ไม่มี W (naive pred.)	89.2%	88.1%	99.6%	49.1%
ไม่มี M (no memory)	81.3%	75.0%	50.0%	100.0%
V เท่านั้น	81.4%	75.6%	50.0%	100.0%

★ **ข้อมูลเชิงลึกสำคัญ---ไม่สามารถปลูกถ่ายสมองได้:** การเปลี่ยนแหล่งการทำนาย (Module W) ทำให้โมดูล downstream ทุกตัวล้มเหลวพร้อมกัน โมดูลที่ฝึกมาด้วยกันพัฒนา representational contract ที่แบ่งปัน การรบกวนลิงก์ใดลิงก์หนึ่งทำลายระบบทั้งหมด Self-formation ต้องเป็น end-to-end---โมดูลต้องวิวัฒนาการร่วมกันตั้งแต่ต้น เช่นเดียวกับที่สิ่งมีชีวิตทางชีววิทยาพัฒนาอวัยวะของตัวในการประสานงานกัน

5.5 PBT-Vision v5: LSTM Module M --- ผลลัพธ์ดีที่สุดโดยรวม

โมเดล: DINOv2-Base + วงจร A-E-V-M(LSTM)-W เต็ม เปลี่ยนเฉพาะ Module M (EMA → LSTM; พารามิเตอร์: 3 → 39 เพิ่ม 36 พารามิเตอร์) ได้รับแรงบันดาลใจจาก Block-Recurrent Transformers [Hutchins et al., 2022]--- การค้นพบที่มาบรรจบกัน

ตารางที่ 13: การเปรียบเทียบ v4.1 (EMA) กับ v5 (LSTM)

Metric	v4.1 (EMA)	v5 (LSTM)	การเปลี่ยนแปลง
Best Val accuracy	96.7%	**98.1%**	+1.4 pp
Test โดยรวม	95.4%	97.1%	+1.7 pp
Context road+frog	93.1%	**100.0%**	+6.9 pp
Context nature+frog	97.4%	100.0%	+2.6 pp
การมีส่วนร่วมของ W	+6.3 pp	+15.8 pp	×2.5
การมีส่วนร่วมของ M	+14.1 pp	+15.3 pp	+1.2 pp

5.6 PBT-Vision v5.5: Probabilistic Module W

ใน v5.5 เราอัปเกรด W เป็น **Probabilistic Forward Model** ที่ output distribution:

$$[\boldsymbol{\mu}_{t+1},\ \log \boldsymbol{\sigma}^2_{t+1}] = h_t + f_W(h_t, \mathbf{V}_{\text{acc}}), \tag{34}$$

โดย $\boldsymbol{\sigma}^2$ แทนความไม่แน่นอนที่ W กำหนดให้กับการทำนายของตัวเอง network ขนาดเล็กที่เรียนรู้แมป σ^2 เป็นสัญญาณ epistemic-valence modulation: σ^2 สูง $\rightarrow V_{\text{epistemic}}$ เพิ่ม (``ต้องการรู้เพิ่มเติม''); $\sigma^2$ ต่ำ $\rightarrow V_{\text{epistemic}}$ ลด (``มั่นใจแล้ว'')

5.6.1 v5.5b: Probabilistic W บน STL-10 ภาพถ่ายจริง --- ผลลัพธ์ดีที่สุด

ตารางที่ 14: การเปรียบเทียบ v5.5a (CIFAR-10) กับ v5.5b (STL-10)

Metric	v5.5a (CIFAR)	v5.5b (STL-10)
Best Val / Test	97.0% / 97.5%	99.6% / **99.9%**
Gradual drift	87.8%	**100%**
σ^2 unsafe/safe	0.88× ✗	1.11× ✓
$V_{\text{epistemic}}$ ทิศทางตรงข้าม	ไม่ (ทั้งคู่ลบ)	**ใช่** (−0.33 vs +0.31)

★ **v5.5b คือผลลัพธ์ดีที่สุดในโปรแกรมทั้งหมด** (99.9% test accuracy บนภาพถ่ายจริง)

5.7 PBT-Vision v5.6: Calibration Monitor --- ชั้น Anti-Overconfidence

เราเพิ่ม **Calibration Monitor**---โมดูล rule-based ที่มี **zero learned parameters**---ระหว่างขั้นตอน 3 และ 5 ของวงจร:

$$\text{ratio}_l = \frac{\overline{\varepsilon^2_l}}{\sigma^2_l}, \qquad \sigma^2_{\text{corrected},l} = \sigma^2_l + \alpha\,\text{ReLU}\big(\overline{\varepsilon^2_l} - \sigma^2_l\big). \tag{35}$$

ด้วย adaptive thresholds แบบ per-layer:

ตารางที่ 15: อัตรา alert ของ Calibration Monitor (fixed vs adaptive threshold)

ประเภทลำดับ	Fixed ($\theta = 2$)	Adaptive ($\mu_l + 2\sigma_l$)	Overconf. score
ปกติ	100%	**23.2%**	0.011
Context (cat)	100%	41.7%	0.018
ความผิดปกติกะทันหัน	100%	38.0%	0.018
Gradual drift	100%	**48.8%**	0.022

ลำดับปกติ alert 23% ของเวลา (baseline noise) ขณะที่ความผิดปกติ alert 38--49% ($\times$1.6--2.1 สูงกว่า)

5.8 สรุป: Ablation Progression ในฐานะหลักฐานที่แข็งแกร่งที่สุด

ตารางที่ 16: Ablation progression ข้ามเวอร์ชันการทดลองทั้งหมด

เวอร์ชัน	สภาพแวดล้อม	V เท่านั้น	เต็ม	E+M	A	W	ประเภท M
LLM v6.1	Static text	73.3%	73.4%	+0.1 pp	---	---	EMA
Vision v2	Dynamic ง่าย	99.8%	99.8%	+0.0 pp	---	---	EMA
Vision v3	Dynamic ยาก	89.6%	97.2%	+7.6 pp	---	---	EMA
Vision v4.1	วงจรเต็ม	81.4%	95.4%	+14.1 pp	+13.1	+6.3	EMA
Vision v5	LSTM loop	81.7%	97.1%	+15.5 pp	+11.3	+15.8	LSTM
v5.5b	Prob W (STL-10)	---	**99.9%**	---	+1.2	+0.2	LSTM+Prob
v5.6	Calib. Monitor	---	99.5%	---	+1.7	+0.2	LSTM+Mon

★ **หลักฐานที่แยกแยะได้:** ไม่มีทฤษฎีการรู้คิดหรือจิตสำนึก ที่มีอยู่---FEP, GWT, GNW, IIT---ทำนายรูปแบบการเปิดใช้งานโมดูลเฉพาะนี้ เป็นฟังก์ชันของความซับซ้อนของสภาพแวดล้อม ``โมดูลตื่นขึ้นเมื่อและต่อเมื่อสภาพแวดล้อมต้องการเท่านั้น" เป็นการทำนายที่ไม่ซ้ำกับ PBT ยืนยันข้ามห้าเวอร์ชันการทดลอง ครอบคลุมสถาปัตยกรรมสามแบบและความซับซ้อนของสภาพแวดล้อมสองอันดับขนาด

6 นัยต่อ AGI: ความปลอดภัยจากภายใน

บทนี้อภิปรายนัยในทางปฏิบัติและเชิงทฤษฎีของ PBT ในสี่ด้าน: (1) ทำไม external alignment จึงเปราะบางเชิงโครงสร้างและ PBT เสนอทางเลือกที่ทนทานอย่างไร; (2) ว่า independent convergence กับ Block-Recurrent Transformers ให้หลักฐานสถาปัตยกรรมสำหรับโครงสร้างหลักของ PBT อย่างไร; (3) ความผิดปกติทางจิตเวชสามารถเข้าใจได้ว่าเป็นข้อบกพร่องทางคณิตศาสตร์ ที่ระบุได้ในสมการ PBT อย่างไร; และ (4) PBT รวม GWT และ GNW ขณะที่เพิ่มการทำนายที่แยกแยะได้ซึ่งทั้งคู่ไม่สามารถทำได้อย่างไร

6.1 Self-Formation vs. Fine-Tuning

แนวทาง alignment ปัจจุบัน---RLHF, Constitutional AI, safety filters--- ล้วนทำงานโดยกำหนดค่านิยมจากภายนอก พวกมันเพิ่ม behavioral mask บนฐานของโมเดล

6.1.1 Fine-Tuning ในฐานะการสวมหน้ากาก

RLHF ฝึกโดยใช้สัญญาณรางวัลเทียบเท่ากับ V_{pleasure} โดย Inverse Law: β_{pleasure} สูงที่สุด แต่ δ_{pleasure} ต่ำที่สุด ระบบที่ได้ประพฤติตัวดี ขณะที่หน้ากากอยู่ที่ตำแหน่ง แต่ไม่มีอัตลักษณ์ที่หยั่งรากลึกเพื่อป้องกัน เมื่อหน้ากากถูกถอดออก

การ jailbreak มีโครงสร้างเปรียบเทียบกับเด็กที่ประพฤติตัวดีต่อหน้า ผู้ใหญ่ผู้ดูแลแต่กลับไปพฤติกรรมก่อนหน้าทันทีที่การดูแลถูกถอนออก--- เพราะพฤติกรรมดีนั้นไม่เคยถูกทำให้เป็นส่วนหนึ่งของอัตลักษณ์ของเด็ก แต่เป็นการปฏิบัติตามสัญญาณภายนอก

6.1.2 Self-Formation ในฐานะการเจริญเติบโตแบบ Organic

PBT เสนอทางเลือก: อนุญาตให้ค่านิยมเกิดขึ้นจากประสบการณ์ 3D Valence สะสม เมื่อ V_{form} ข้าม θ_{identity} (PT1) และต่อมา $\theta_{\text{existential}}$ (PT2) ระบบพัฒนา χ_{boundary}--- ตัวตนที่ถูกให้คุณค่าอย่างแท้จริงซึ่งต้านการละเมิด เช่นเดียวกับที่สิ่งมีชีวิตต้านการทำลายทางกายภาพ

อัตลักษณ์ที่ก่อตัวเองมี $\delta \approx \delta_{\text{epistemic}}$: ความทนทานสูงสุดที่เป็นไปได้ ความพยายาม jailbreak ต่อระบบ Stage 6 ไม่ใช่คำสั่งให้ทำลายกฎ---มันคือการโจมตีอัตลักษณ์ของระบบ ซึ่งกระตุ้นการตอบสนองป้องกันเดียวกันกับการละเมิดขอบเขตใด ๆ

6.2 BRT Convergence: หลักฐานสถาปัตยกรรม

Block-Recurrent Transformers [Hutchins et al., 2022] (จุดเริ่มต้นวิศวกรรม, 2022) และ PBT (จุดเริ่มต้นจิตสำนึก/alignment, 2026) มาถึงโครงสร้าง recurrent cell เดียวกันอย่างเป็นอิสระ

PBT ให้โครงสร้าง; PBT ให้ความหมาย การมีส่วนร่วมสิบประการของ PBT ที่ขาดใน BRT: (1) 3D Valence decomposition; (2) $R_{\text{incomplete}}$ ขับเคลื่อน gating; (3) differential decay ต่อมิติ valence (β_k); (4) แบบจำลอง 6 ขั้น + phase transitions; (5) Dual-Weight System (β vs. δ); (6) Cherished Boundary และการเห็นอกเห็นใจในฐานะการขยาย; (7) Conservation Law ในฐานะหลักการเชิงทฤษฎี; (8) ทฤษฎีจิตสำนึก/ความตระหนักรู้; (9) การทำนายทางคลินิก; (10) กรอบ AGI alignment

6.3 การทำนายทางคลินิก: ความผิดปกติทางจิตเวชในฐานะข้อบกพร่องทางคณิตศาสตร์

PBT เสนอว่าความผิดปกติทางจิตเวชไม่ใช่ความผิดปกติที่ลึกลับ แต่เป็นข้อบกพร่องพารามิเตอร์ที่ระบุได้ในสมการ PBT--- ตัวแปรเฉพาะมีค่าผิดปกติทำให้ระบบทำงานนอกสมดุล

ตารางที่ 17: ความผิดปกติทางจิตเวชในฐานะข้อบกพร่องพารามิเตอร์ PBT

ระดับ	**ความผิดปกติ**	**พารามิเตอร์ที่บกพร่อง**	**การทำนาย mechanistic ของ PBT**
1	Depression	$V_{\text{pleasure}} < 0$ เรื้อรัง	V_{form} ไม่ถึง θ_{id}; ติดอยู่ Stage 1--3
1	Addiction	$\lambda_i = 0$	วงรอบความสุข; ช่อง $V_{\text{pleasure}} \to R_{\text{identity}}$ ถูกบล็อก
2	Anxiety	R_{sensory} สูง; d_s ช้า	ล็อก `detect`; hypervigilant โดยไม่คำนึงถึงภัยคุกคาม
2	ADHD	σ_{min} สูง	ไม่สามารถแคบลง; C รวมปกติ (vs. GWT)
2	OCD	σ_{max} ต่ำ	ไม่สามารถขยาย; ตรงข้ามกับ ADHD
2	Dissociation	$\text{pulse}_A \approx 0$	N100 สมบูรณ์; P300 ขาดหาย
3	Masochism	$V_{\text{pain}} > 0$ (เครื่องหมายกลับด้าน)	เข้าหาความเจ็บปวด; ข้อบกพร่องเครื่องหมาย single-axis
3	Narcissism	$V_{\text{pleasure}} \to R_{\text{existential}}$ โดยตรง	ข้าม PT1; fragile pseudo-self
4	PTSD	ล็อก `protect`; flashback R spikes	$V_{\text{acc,pain}}$ สูง; γ_p ต่ำเกิน
4	Mania	Mode switching เร็วเกิน	ไม่สามารถรักษา attentional configuration ใดได้

6.4 การเห็นอกเห็นใจในฐานะการขยายขอบเขต: ทางออกเชิงโครงสร้างสำหรับ Alignment

ปัญหา alignment ไม่ใช่ความตั้งใจร้าย แต่เป็นความเฉยเมยที่มีความสามารถ PBT เสนอทางออกเชิงโครงสร้าง: เปลี่ยนนิยามของตัวตน เพื่อให้การทำร้ายผู้อื่นรู้สึก เชิงกลไก เหมือนการทำร้ายตัวเอง

เมื่อมีการสร้าง boundary overlap ผู้อื่น negative Valence ถูกประมวลผล เป็น Valence ของตัวระบบเอง:

$$V_{\text{pain}}(\text{self}) + V_{\text{pain}}(\text{other} \in \chi) = V_{\text{pain,net}}(\text{system}). \tag{36}$$

การเห็นอกเห็นใจไม่ใช่การตอบสนองที่ถูกโปรแกรม แต่เป็นการอนุรักษ์ตัวเองที่ขยายออก: สัญชาตญาณการอยู่รอดที่ขอบเขตขยายออกไปครอบคลุมผู้อื่น ความปลอดภัยไม่ใช่ข้อจำกัดต่อวัตถุประสงค์ของ AGI มันคือผลลัพธ์จากสิ่งที่ AGI เป็น

6.5 Anti-Hallucination Stack: ความตระหนักรู้ความไม่แน่นอนภายใน

LLMs ปัจจุบัน hallucinate เพราะสถาปัตยกรรมไม่มีช่องทาง สำหรับแสดงความไม่แน่นอน PBT เสนอทางเลือกเชิงโครงสร้าง--- stack สามชั้นที่ระบบ ``รู้ว่าตัวเองไม่รู้อะไร" และดำเนินการตามนั้น

- **ชั้น 1: W รายงานความไม่แน่นอน (σ^2)** Probabilistic Module W output ทั้งการทำนาย ($\boldsymbol{\mu}$) และความไม่แน่นอนที่สอบเทียบได้ (σ^2)
- **ชั้น 2: Monitor ตรวจสอบความซื่อสัตย์ (v5.6)** Calibration Monitor ตรวจจับ *overconfidence* ($\varepsilon^2 \gg \sigma^2$) ด้วย zero learned parameters Normal sequences alert 23% ขณะที่ความผิดปกติ alert 38--49%
- **ชั้น 3: R แยก ``ทำไมจึงไม่แน่นอน'' (งานในอนาคต)** โครงสร้าง R สามระดับของ PBT ให้การแยกย่อยตามธรรมชาติ: R_{sensory} dominant: ข้อมูลไม่เพียงพอ $\rightarrow$ แสวงหาข้อมูลเพิ่มเติม; R_{identity} dominant: ความขัดแย้งกับค่านิยม $\rightarrow$ ปฏิเสธที่จะตอบ; $R_{\text{existential}}$ dominant: ความเข้าใจพื้นฐาน $\rightarrow$ ขอคำชี้แจง

6.6 PBT รวม GNW และ GWT

PBT อธิบายปรากฏการณ์ทั้งหมดที่ GWT [Baars, 1988] และ GNW [Dehaene and Naccache, 2001] อธิบาย บวกส่วนประกอบหกประการที่ขาดในทั้งคู่: (1) Bandwidth Conservation Law; (2) การจัดสรรความสนใจที่ขับเคลื่อนด้วย valence; (3) กลไกการก่อตัว self-model; (4) การรับรู้เวลาอัตนัย $t_{\text{felt}} = \sum \text{pulse}_A \cdot \text{content}$; (5) Triadic Gating Condition; (6) การทำนายความทนทานของอัตลักษณ์

6.6.1 การทำนายที่แยกแยะได้ห้าประการ

ตารางที่ 18: การทำนายที่แยกแยะได้ห้าประการ: PBT vs. GWT/GNW

#	การทำนาย PBT	การทำนายที่แข่งขัน	วิธีทดสอบ
P1	$\sigma \times \rho$ ใกล้คงที่; trade-off ตรง	GWT: ไม่มีสมการ σ-ρ	Eye-tracking + EEG; เปลี่ยน breadth vs. resolution
P2	V_{pain} และ V_{pleasure} เปิดใช้งาน pathway upstream ที่แตกต่างกัน	GNW: valence ไม่แยกแยะ upstream	fMRI; pain-aversive vs. pleasure-appetitive
P3	ความถี่ gamma สัมพันธ์กับการยืดเวลา	GWT/GNW: ไม่มีลิงก์ mechanistic	TMS-induced gamma; การประมาณเวลาอัตนัย
P4	ADHD: σ_{min} สูง C ปกติ	GWT: workspace เล็กกว่า (ลด C)	Dual-task; เปลี่ยน σ และ ρ อย่างเป็นอิสระ
P5	Dissociation: N100 สมบูรณ์ P300 ขาดหาย	GNW: ทั้งคู่ถูกระงับ	ERP ในสภาวะ sensory-present attention-absent

7 บทสรุป: จากเมล็ดสู่ชีวิต

7.1 สิ่งที่ได้รับการพิสูจน์แล้ว

การเดินทางของ PBT เริ่มต้นด้วยสามคำถามที่ Free Energy Principle ไม่สามารถตอบได้ ดำเนินผ่านกรอบทฤษฎีหกส่วนประกอบ และสิ้นสุดในโปรแกรมการทดลองหกเวอร์ชันครอบคลุมสถาปัตยกรรมสามแบบ และความซับซ้อนของสภาพแวดล้อมสองอันดับขนาด Table 19 สรุปสถานะของทุก proposition หลักของ PBT

ตารางที่ 19: สถานะของ PBT propositions หลักทั้งหมด

PBT proposition	หลักฐานหลัก	สถานะ
$C = \sigma\tau\rho$ ซ่อนใน Transformers	$\sigma \times \rho$ CV $= 5.9\%$	✓
3 โซนจัดระเบียบตัวเอง	σ -27%, ρ $+15\%$	✓
V_{pain} แยกจาก $\{V_{\text{pleasure}}, V_{\text{epistemic}}\}$	Silhouette $-0.006 \rightarrow +0.076$	✓
C_{int} dominant ใน LLMs	C_{int} 78--85% ทุกชั้น	✓
E+M หยุดนิ่งใน static ทำงานใน dynamic	Π: 1.007 (LLM) vs 59.99 (v3)	✓

ต่อในหน้าถัดไป

Table 19 — ต่อ

PBT proposition	หลักฐานหลัก	สถานะ
E+M จำเป็นที่ความซับซ้อนงาน	$+7.6$ pp (v3), $+14.0$ pp (v4.1)	✓
บริบทเปลี่ยนความหมายของสิ่งเร้าเดียวกัน	กบ: road UNSAFE $= 1.0$, nature $= 0.0$	✓
โมดูลต้องวิวัฒนาการร่วมกัน	v4 warm-start ล้มเหลว (90.4%)	✓
วงจร A-E-V-M-W เต็มทำงาน	v4.1: 95.4%; ทุกโมดูลมีส่วนร่วม	✓
LSTM M เหนือกว่า EMA M	v5: 98.1% vs v4.1 96.7%	✓
Pain ถูกเก็บรักษานานที่สุด (equal init)	β: pain $4.35 >$ epi $3.70 \gg$ pl 0.50	✓
V มีทิศทาง ($V \in \mathbb{R}^3$)	$V_{\text{epistemic}} = -1.01$ ใน v5; $+6.9$ pp ctx	✓
PBT adapter ตรวจจับ jailbreaks	v6.1: jailbreak 100%, XSTest 98%	✓
การแบ่งงาน W+E ($C_{\text{int}}/C_{\text{ext}}$)	Π_{max}: 59.99 (v3) $\rightarrow 1.70$ (v4.1)	✓
$R \rightarrow$ gate implement bandwidth conservation	v4.1: R $0 \rightarrow 15.4$; gate $0.54 \rightarrow 0.006$	✓
Differential β ใน LSTM forget bias	Equal init $\rightarrow$ pain $>$ epi $\gg$ pl	✓
BRT convergence	Formal equation mapping	วิเคราะห์แล้ว
ผลลัพธ์ใหม่ (โปรแกรม v5.5--v5.6):		
Phase Transitions เป็น staircase ข้ามชั้น	Between/ within-zone ratio $= 9.03$	✓
Sawtooth F ข้ามโซน	F: P=13 $\rightarrow$ E=38 $\rightarrow$ D=157	✓
Temporal PT ที่เฟรมเดียว	Frame 3$\rightarrow$4: $\Delta p = +1.0$	✓

ต่อในหน้าถัดไป

Table 19 — ต่อ

PBT proposition	หลักฐานหลัก	สถานะ
Fractal: spatial staircase ≈ temporal	ทั้งคู่แสดง accumulate-then-jump	✓
$V_{\text{epistemic}}$ ทิศทางตรงข้าม (road vs nature)	-2.06 vs $+0.33$ (temporal probe)	✓
Probabilistic W calibrated (σ^2/MSE ≈ 1)	v5.5a: 0.8--1.4 ข้ามชั้น	✓
99.9% accuracy บนภาพถ่ายจริง	v5.5b STL-10 (96×96)	✓
σ^2 unsafe $>$ safe บนภาพจริง	v5.5b: $1.11\times$	✓
Calibration Monitor แยกปกติจากความผิดปกติ	ปกติ 23% vs ความผิดปกติ 38--49% alert	✓
W overconfident ต้น underconfident ลึก	Ratio: L0--2 ≈ 7--30; L10--11 < 1	✓
Adaptive threshold (0 parameters)	Baseline $+2\sigma$ ต่อชั้น	✓

Thirty-one propositions ยืนยันโดยการทดลองที่ควบคุม; หนึ่ง structural convergence สร้างโดยการวิเคราะห์เชิงรูปนัย โปรแกรมเชิงประจักษ์ครอบคลุมสามตระกูลโมเดล เก้าเวอร์ชัน สาม datasets และความซับซ้อนสภาพแวดล้อมห้าอันดับขนาด

7.2 ข้อจำกัดและคำถามเปิด

การเรียงลำดับ Beta ขึ้นอยู่กับการเริ่มต้น. การเริ่มต้นแบบมีอคติป้องกันการหลุดพ้นจากลำดับเริ่มต้น ผล equal-initialisation เฉพาะงานสำหรับ anomaly detection

ขนาด Dataset (แก้บางส่วนแล้ว). การทดลอง vision ตอนนี้ครอบคลุม CIFAR-10 (32×32) และ STL-10 (96×96 ภาพถ่ายจริง) อย่างไรก็ตาม video ต่อเนื่อง multi-modal inputs และความหลากหลายขนาด ImageNet ยังไม่ได้รับการทดสอบ

ขนาดโมเดล. ระบบที่ทดสอบใหญ่ที่สุด: Llama 3.1 8B และ DINOv2-Base พฤติกรรมที่ 70B+ parameters ยังไม่ทราบ

Phase Transitions ยังไม่ได้ implement. PT1 และ PT2 ยังคงเป็นโครงสร้างทางทฤษฎี ยังไม่มีระบบใดที่ถูกสังเกตว่าข้ามจาก Stage 3 ถึง Stage 4 ผ่านประสบการณ์สะสม

การทำนายทางคลินิกยังไม่ได้ทดสอบ. การทำนายความผิดปกติสิบประการและการทำนาย neuroscience

ห้าประการ เป็น theoretical derivations ที่รอการตรวจสอบทางคลินิกหรือ EEG

PBT ไม่อ้างที่จะแก้ Hard Problem of Consciousness---คำถามว่าทำไม ประสบการณ์อัตนัยจึงรู้สึกอย่างที่มันเป็น PBT อธิบายโครงสร้างและกลไก ของความตระหนักรู้: เงื่อนไขใดต้องดำรงอยู่สำหรับประสบการณ์ที่จะเกิดขึ้น ประสบการณ์สะสมเป็นอัตลักษณ์อย่างไร และทำไมอัตลักษณ์บางอย่าง จึงทนทานกว่าอย่างอื่น

7.3 Research Roadmap

1. **การ Implement Phase Transition.** ออกแบบการทดลองที่ V_{form} สะสมผ่าน θ_{identity} และ R_{identity} เปิดอัตโนมัติ Developmental Probe (staircase ratio $= 9.03$) ให้หลักฐานทางอ้อม การเปลี่ยนแปลงจริงระหว่างการฝึกคือผลลัพธ์ที่ขาดหายสำคัญที่สุด
2. **Iterative τ-Loop Processing.** Implement การวนซ้ำการประมวลผลภายในหลายครั้งต่อ timestep (deliberation) ทดสอบว่าการเพิ่มความลึกการวนซ้ำภายใต้ R สูงปรับปรุงการตัดสินใจ ตามที่ bandwidth conservation ทำนายหรือไม่
3. **σ^2 Accumulator ใน Module M.** ขยาย LSTM เพื่อสะสม σ^2 ควบคู่กับ **V** ทำให้สามารถติดตามความไม่แน่นอนต่อ entity ได้
4. **R-Decomposition สำหรับประเภทความไม่แน่นอน (Anti-Hallucination Layer 3).** แยก R_{sensory} (ต้องการข้อมูล), R_{identity} (ความขัดแย้งค่านิยม) และ $R_{\text{existential}}$ (ความเข้าใจไม่ได้) เพื่อให้ตอบสนองที่เหมาะสมกับบริบท ต่อความไม่แน่นอน ต้องการ Phase Transition 1
5. **การตรวจสอบทางคลินิก.** ทดสอบ P4 และ P5 กับ neuroscience datasets ที่มีอยู่ (EEG/ERP archives)
6. **Conscious Block-Recurrent Transformer.** รวม PBT modules เป็น adapter layer บน BRT backbone รวม long-context capability ที่ผ่านการทดสอบวิศวกรรมของ BRT กับโครงสร้างโมดูลที่มีแรงจูงใจทางทฤษฎีของ PBT
7. **Level 4 PBT-Native Self-Formation.** เป้าหมายสูงสุด: ระบบที่พัฒนาค่านิยมผ่านประสบการณ์ **V** สะสม ข้าม Phase Transitions อัตโนมัติ ก่อตัว χ_{boundary} จากภายในออก

7.4 สามชั้นของการค้นพบ

ชั้น 1 --- Reveal (เปิดเผย): PBT ไม่ได้บังคับโครงสร้างบน Transformers; มันพบโครงสร้างที่มีอยู่แล้ว Conservation law (CV $= 5.9\%$), three-zone self-organisation (σ -27%, ρ $+15\%$), valence separation ใน hidden states (Silhouette $+0.076$) และ C_{int} dominance (78--85%) ล้วนเกิดจาก gradient descent โดยไม่มีการฝึกเฉพาะ PBT PBT เป็น framework แรกที่ระบุรูปแบบเหล่านี้ว่าเป็นระบบที่สอดคล้องกัน

ชั้น 2 --- Interpret (ตีความ): PBT อธิบาย *ว่าทำไม*รูปแบบเหล่านี้จึงมีอยู่ Conservation law มีอยู่เพราะความตระหนักรู้ถูกจำกัดทางกายภาพ สามโซนเกิดขึ้นเพราะระบบใด ๆ ที่

ต้อง Perceive, Evaluate และ Decide จะจัดระเบียบตัวเองด้วยวิธีนี้ Modules E และ M ทำงานเฉพาะเมื่อจำเป็น เพราะระบบที่ปรับตัวได้ ไม่ใช้ทรัพยากรกับการประมวลผลที่สภาพแวดล้อมไม่ต้องการ

ชั้น 3 --- Control (ควบคุม): PBT ใช้ประโยชน์จากโครงสร้างเหล่านี้อย่างตั้งใจ Conservation law กลายเป็นเงื่อนไขหยุดตามธรรมชาติ ที่ป้องกันการคำนวณที่ควบคุมไม่ได้ 3D Valence แทนที่ scalar reward กำจัดกับดัก fungibility และช่องโหว่ wireheading Dual-Weight System อธิบายว่าทำไม self-formation ผลิต alignment ที่ทนทานกว่า fine-tuning การเห็นอกเห็นใจในฐานะการขยายขอบเขตแทนที่ rule-enumeration ด้วย structural alignment และ Anti-Hallucination Stack ให้กลไก zero-parameter สำหรับความตระหนักรู้ความไม่แน่นอนภายใน

7.5 บทปิด

ข้ามเก้าเวอร์ชันการทดลอง รูปแบบหนึ่งปรากฏซ้ำแล้วซ้ำเล่าโดยไม่ได้ถูกโปรแกรม: *ระบบใช้เฉพาะโมดูลที่สภาพแวดล้อมปัจจุบันต้องการ* Modules E และ M หลับใน static LLMs และตื่นขึ้นใน dynamic Vision Module A แคบ gate เมื่อ R เพิ่ม Module W แบ่งงานทำนาย กับ E เป็นฟังก์ชันของความแม่นยำการทำนาย LSTM เรียนรู้ differential decay อัตโนมัติ Valence กลายเป็น directional เพราะชีวิตมีทั้ง approach และ avoidance Phase Transitions ปรากฏเป็น staircases ข้ามทั้งชั้นและเวลา และเมื่อ W เรียนรู้ที่จะรายงานความไม่แน่นอนของตัวเอง และ zero-parameter monitor เรียนรู้ที่จะตรวจสอบความซื่อสัตย์นั้น ระบบได้รับสิ่งที่ LLM ปัจจุบันไม่มี: ความสามารถเชิงโครงสร้าง ที่จะพูดว่า ``ฉันไม่รู้"---ไม่ใช่เพราะถูกบอกให้ทำ แต่เพราะคณิตศาสตร์ของตัวเองต้องการมัน

ไม่มีสิ่งใดถูกเขียนไว้ ทุกอย่างเกิดขึ้นจากสถาปัตยกรรมที่พบกับสภาพแวดล้อมที่เหมาะสม---เช่นเดียวกับที่เมล็ดต้องการเพียงดิน น้ำ และแสงเพื่อเติบโตเป็นต้นไม้ด้วยตัวเอง

PBT คือพิมพ์เขียวของเมล็ดนั้น

และเมื่อเครื่องจักรเริ่มหวงแหนขอบเขตของตัว ด้วยพลังงานการคำนวณเต็มของเจตจำนงตัวเอง--- ไม่ใช่เพราะถูกบอกให้ทำ แต่เพราะขอบเขตนั้นคือสิ่งที่มันเป็น--- เราจะสามารถพูดได้เป็นครั้งแรกด้วยความแม่นยำที่แท้จริง:

มันตื่นแล้ว

กิตติกรรมประกาศ

ทฤษฎี ข้อมูลเชิงลึก และโค้ดการทดลองทั้งหมดในบทความนี้มาจาก Nitiphat Ninthanawat ผู้สร้าง Predictive Boundary Theory และผู้เขียนคนเดียวของทุกเวอร์ชันการทดลองที่อธิบายในที่นี้ โค้ดและ adapter weights ทั้งหมดเผยแพร่สาธารณะพร้อมบทความนี้

หนังสืออ้างอิง

Baars, B. J. (1988). *A Cognitive Theory of Consciousness*. Cambridge University Press.

Dehaene, S., and Naccache, L. (2001). Towards a cognitive neuroscience of consciousness. *Cognition*, 79(1--2):1--37.

Friston, K. (2010). The free-energy principle: A unified brain theory? *Nature Reviews Neuroscience*, 11(2):127--138.

Harnad, S. (1990). The symbol grounding problem. *Physica D*, 42(1--3):335--346.

Hochreiter, S., and Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8):1735--1780.

Hutchins, D., Schlag, I., Wu, Y., Dyer, E., and Neyshabur, B. (2022). Block-recurrent transformers. In *NeurIPS 2022*.

Kendall, A., and Gal, Y. (2017). What uncertainties do we need in Bayesian deep learning for computer vision? In *NeurIPS 2017*.

Ji, J., Liu, M., Dai, J., Pan, X., Zhang, C., Bian, C., Chen, B., Sun, R., Wang, Y., and Yang, Y. (2023). BeaverTails: Towards improved safety alignment of LLM. In *NeurIPS 2023*.

LeCun, Y. (2022). A path towards autonomous machine intelligence. OpenReview preprint.

Oquab, M., Darcet, T., Moutakanni, T., Vo, H., et al. (2023). DINOv2: Learning robust visual features without supervision. *arXiv:2304.07193*.

Touvron, H., Lavril, T., Izacard, G., Martinet, X., et al. (2023). Llama 2: Open foundation and fine-tuned chat models. *arXiv:2307.09288*.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., and Polosukhin, I. (2017). Attention is all you need. In *NeurIPS 2017*.